

False Consensus in Adaptive Reasoning - DeepSeek 三 Seed Final-Eval 报告

冻结规则的一次性确证：Accuracy-Compute Pareto、组件机制与提交门槛

2026-07-26

目录

1	执行摘要	1
2	冻结协议与指标口径	2
2.1	一次性边界	2
2.2	三个容易混淆的量	2
3	数据完整性与运行覆盖	3
4	基线与 Governor 的 Accuracy-Compute Pareto	4
4.1	三 seed 主结果	4
4.2	为什么 Conservative 反而更贵	4
4.3	固定预算对照	4
5	(2^4) 组件实验：安全性由什么提供	5
6	Recovery 与 Overthinking	6
7	提交门槛与边界	6
8	结论与下一步	7
9	复现索引	7

1 执行摘要

本轮完成了冻结协议下的 **DeepSeek-R1-Distill-Qwen-7B × MATH500 × seeds 43/44/45** 一次性 final evaluation。每个 seed 都覆盖 500 题，记录完整轨迹与 simple@32 probe，并离线回放 52 个方法，其中包括 Full、5 个固定预算点、naive agreement、Dynasor 风格停止、两个冻结 Governor 规则、36 个 entropy 配置、6 个 majority 配置，以及 (2^4=16) 个组件因子格。

结论很清楚：本轮证实了安全性，但没有证实目标幅度的节省。

- **Conservative** 保住准确率，但不省总生成 token。平均准确率 80.73%，比 Full 高 0.07 个百分点，95% CI 为 $([-0.60, +0.73])$ 个百分点；然而将 probe decode 计入后，总生成 token 增加

4.41%，95% CI 为增加 2.92%-5.84%。

- **Balanced-MATH** 是唯一落在 **Full** 左侧的冻结 **Governor** 点，但节省很小且不确定。平均准确率与 Full 同为 80.67%；平均节省 0.88%，95% CI 为 $([-0.78\%, +2.49\%])$ ，区间跨 0，远低于预注册的 25% 下限。
- 激进基线确实节省 **token**，却明显损害准确率。Naive agreement 节省 48.91%，但损失 16.27 个百分点；Dynasor 风格规则节省 35.78%，但损失 10.93 个百分点。这再次说明 agreement 可以用于排序风险，却不能单独充当安全停止条件。
- 组件实验解释了安全性来自哪里。Persistence 的平均边际准确率收益最大 (+8.27pp)，但平均多用 749 个生成 token；Schema 仅多用 26 token，仍带来 +1.88pp，是成本最低的安全过滤器。
- 继续推理的 **recovery** 价值远高于 **overthinking** 风险。达到统一共识定义的 1,335 条轨迹中，错误共识后翻正确 233 次，正确共识后翻错误 32 次，原始计数比为 7.28:1。该结果是轨迹关联证据，不应解释为停止规则的因果效应。
- 提交门槛未通过。DeepSeek 三 seed 证据块已经完整，但冻结协议还要求 Qwen3-8B、两条正式 CertIndex 基线，以及目标幅度的 token 节省。当前 `primary_gate_pass=false`，不能把本轮写成完整跨模型确证。

冻结方法	准确率	相对 Full 准确率差 [95% CI]	总生成 token 节省 [95% CI]	判定
Full	80.67%	0.00pp	0.00%	参照
Conservative	80.73%	+0.07pp [-0.60, +0.73]	-4.41% [-5.84, -2.92]	准确率过门， token 未过门
Balanced-MATH	80.67%	0.00pp [-0.73, +0.67]	+0.88% [-0.78, +2.49]	准确率过门， token 未过门

2 冻结协议与指标口径

2.1 一次性边界

协议版本为 2026-07-25.1，在新 seed 结果可见前冻结于 commit 0dcc1b1b3e5eded098e90dc83bbbfa48dfdbda8b。本轮没有根据 seed 43/44/45 结果修改规则参数；新增方法若要进入主结果，必须另行注册数据或 seed。因此，这里报告的是确证性评估，不是在测试集上继续调参的 sweep。

项目	冻结值
模型 / 数据集	deepseek-ai/DeepSeek-R1-Distill-Qwen-7B / MATH500
样本	500 题 × seeds 43、44、45，共 1,500 条独立生成轨迹
生成	temperature 0.6；top_p 0.95；reasoning budget 3,072
Probe	simple suffix；每 128 main tokens；输出上限 32
Conservative	patience 8；固定 floor 1,024；certainty + schema
Balanced-MATH	patience 5；level 1-3 floor 768；level 4-5 floor 2,048；certainty + schema

2.2 三个容易混淆的量

1. **Main decode tokens** 是主推理轨迹本身的输出。
2. **Probe decode tokens** 是周期性读出答案产生的额外输出。

3. **Total generated tokens** 是两者之和，也是本报告的主 `compute` 指标。其节省率为 $(1 - \text{method total} / \text{Full main total})$ 。因此，主轨迹缩短并不自动等于 总成本下降；如果 `probe` 足够多，净节省可以变成负数。

`stop coverage` 是规则触发早停的题占比。`false-stop rate` 的分母是已停止题，表示 停止时提交错误答案的比例，不是整个数据集的错误率。所有准确率差和 `token` 节省区间均 按 `seed` 先重采样、再在 `seed` 内成对重采样题目，使用 10,000 次分层 `bootstrap` 得到。

3 数据完整性与运行覆盖

三个 `seed` 均得到 500/500 条轨迹，通过严格 `validator`，且 `evaluator` 对每个 `seed` 产出 52 个方法汇总、16 个 `factorial cell`、32 行失败模式对照，以及 26,000 行 `method-problem` 明细。共执行 26,289 次 `probe`；自然结束 920 条，撞 3,072-token cap 580 条。仅有 5 次空 `probe`，应答为空的比例约 0.019%。

Seed	Probe 数	自然结束 / cap	Wall time	Energy	Prefix cache hit
43	8,660	313 / 187	79.9 min	522 Wh	98.97%
44	8,834	302 / 198	64.5 min	452 Wh	98.98%
45	8,795	305 / 195	71.8 min	457 Wh	98.97%
合计	26,289	920 / 580	3.60 h	1.431 kWh	98.97%

GPU 峰值显存为 30,419 MiB，采样积分得到的 `active GPU time` 为 10,968 秒。`Wall time` 还包括请求调度、答案解析和 CPU 评分长尾，因此不宜只用 `wall time` 推断 GPU 效率；能耗、利用率积分和请求级 `cache` 指标是更直接的运行证据。GPU 记录中没有采样 错误或服务指标错误，API key 已脱敏。

4 基线与 Governor 的 Accuracy-Compute Pareto

4.1 三 seed 主结果




图 1: 三 seed 平均的准确率-总生成 token 权衡。横轴越右越省 token，纵轴越接近 0 越接近 Full。浅蓝带仅用于标出正负 1pp 的视觉邻域；正式门槛见第 7 节。固定预算越短越省，但准确率下降迅速。

方法	准确率	相对 Full	Token 节省	Coverage	False-stop
Full	80.67%	0.00pp	0.00%	0.00%	不适用
Conservative	80.73%	+0.07pp	-4.41%	44.00%	6.32%
Balanced-MATH	80.67%	0.00pp	+0.88%	52.47%	8.32%
Dynasor on simple@32	69.73%	-10.93pp	+35.78%	80.47%	28.59%
Naive agreement	64.40%	-16.27pp	+48.91%	91.53%	35.47%

两个 Governor 点的准确率都稳定在 Full 附近，而高 coverage 的 agreement 基线出现 10-16pp 的明显损失。这个差异不能只归因于 patience：冻结 Governor 还使用 minimum maturity、certainty 和 schema validity，以避免在答案尚未成熟、读出不确定 或答案结构无效时停止。

4.2 为什么 Conservative 反而更贵

三 seed 中 Conservative 的主轨迹均明显缩短，但每题还产生约 405 个 probe decode tokens。其平均总生成量分别为 2,373、2,386、2,395，均高于对应 Full 的 2,259、2,302、2,291。因此三个 seed 的净节省分别为 -5.06%、-3.63%、-4.54%，不是由单个 异常 seed 驱动。

Balanced-MATH 更早开放简单题停止，使 coverage 从 44.00% 提高到 52.47%，平均主 轨迹约 1,878 tokens；加上约 386 个 probe tokens 后，总量才略低于 Full。三个 seed 都位于 Full 左侧，但幅度只有 0.12%、1.66%、0.87%，bootstrap 区间仍跨 0。

4.3 固定预算对照

固定上限	准确率	相对 Full	总 token 节省
512	41.07%	-39.60pp	76.71%
1,024	58.13%	-22.53pp	55.35%
1,536	68.00%	-12.67pp	36.20%
2,048	74.93%	-5.73pp	20.96%
3,072	80.60%	-0.07pp	-0.49%

固定预算曲线说明 MATH500 的准确率增益在 2,048 tokens 后仍未耗尽。Balanced-MATH 能在接近 Full 的准确率下略微左移，优于统一 3,072 cap；但现有 probe 密度和读出成本 不足以达到预注册的 25%-30% 节省目标。

5 (2^4) 组件实验：安全性由什么提供

因子格独立切换 schema validity、minimum maturity、certainty 和 persistence。下表是 某组件从 off 变为 on 后，在其余 (2^3) 个组合上取平均，再对三 seed 求均值的边际 效应。正的 token 差表示更贵，负的 coverage / false-stop 差表示停止更少但更安全。




图 2: 四个组件跨三 seed 的平均边际效应；误差线为 seed 间样本标准差。Persistence 的安全收益最大，同时计算代价也最大；Schema 是最便宜的安全过滤器。

组件	准确率效应	总 token 效应	Coverage 效应	False-stop 效应
Schema	+1.88pp	+26	-2.48pp	-2.25pp
Maturity	+3.45pp	+199	-3.38pp	-4.06pp
Certainty	+2.08pp	+233	-12.76pp	-5.71pp
Persistence	+8.27pp	+749	-29.31pp	-17.71pp

结果支持以下机制解释：

- **Schema** 主要移除格式或任务结构无效的读出，成本很低，三 seed 的效应方向一致。

- **Maturity** 阻止规则在最低推理长度之前提交，保留了较多后续 recovery。
- **Certainty** 过滤带显式不确定性的读出，显著降低覆盖率，说明“不确定但一致”的 checkpoint 并不少见。
- **Persistence** 要求共识连续存在，是最强的防错组件，也会错过最多真正可安全提前提交的题，因此代价最大。

这些是完整因子格上的边际平均，不是彼此独立的因果贡献；组件之间存在交互，四个数字不能简单相加来预测某条规则。它们适合回答“哪个组件承担主要安全成本”，不适合据此在已观察的三个 seed 上重新选参数。

6 Recovery 与 Overthinking

统一机制定义使用最近 5 个 probe、至少 3 个有效数学答案、dominant share 至少 0.8。第一次达到该共识时答案错而终局正确，记为 recovery；当时正确而终局错误，记为 overthinking。Haldane ratio 使用 $((R+0.5)/(O+0.5))$ ，以减少小计数不稳定性。

Seed	达到 / 未达 到共识	Recovery	Overthinking	Stable correct	Persistent wrong	Haldane ratio [95% CI]
43	448 / 52	75	10	301	62	7.19 [4.14, 15.91]
44	441 / 59	80	10	285	66	7.67 [4.33, 16.64]
45	446 / 54	78	12	284	72	6.28 [3.81, 13.00]
合计	1,335 / 165	233	32	870	200	原始计数比 7.28

在已达到共识的轨迹中，自然结束组有 149 次 recovery、3 次 overthinking、654 次 stable correct、16 次 persistent wrong；撞 cap 组分别为 84、29、216、184。也就是说，persistent wrong 和 overthinking 几乎都集中在未自然收尾的轨迹里。MATH level 4-5 贡献了 159/200 的 persistent wrong 和 148/233 的 recovery，进一步说明难题既更需要继续推理，也更容易在预算内保持错误。

该分析不能证明“继续生成”对单题必然有益，因为是否自然结束、是否撞 cap 与题目难度高度相关。它能稳健支持的结论是：在当前轨迹分布中，过早停止没收 **recovery** 的机会 远多于它避免 **overthinking** 的次数。

7 提交门槛与边界

冻结协议对 Conservative 预注册了准确率平均下降不超过 1.5pp、总生成 token 至少节省 12%、至少 2 个 seed 位于 Full 左侧；对 Balanced-MATH 预注册了准确率下降不超过 3pp、总节省至少 25%、单模型下降不超过 5pp。协议整体还要求 DeepSeek 与 Qwen3-8B、完整方法集和正式 CertIndex 基线。

Gate	状态	原因
Conservative accuracy	PASS	+0.07pp, 相对 Full 无可见下降
Conservative token / Pareto-left seeds	FAIL / FAIL	-4.41%; 0/3 seed 正节省
Balanced accuracy / per-model floor	PASS / PASS	0.00pp; 高于 -5pp floor
Balanced token	FAIL	+0.88%, 低于 25% 下限
Complete models / three seeds per model-method	FAIL	Qwen3-8B final-eval 未执行
Formal baselines present / three seeds	FAIL	两条 CertIndex 独立流未执行
Primary gate	FAIL	完整性和 token 门槛均未满足

这里的 Dynasor 结果是在共同 simple@32 checkpoint 流上回放停止逻辑, 适合做 prompt-matched 对照, 但不等于协议中 interval 64、cap 20 的 faithful CertIndex 独立运行。因此不能把它计作 formal baseline。

8 结论与下一步

本轮最可信的结论不是“Governor 已达到最终节省目标”, 而是更窄也更有价值的三点:

1. 冻结 Governor 规则在 DeepSeek 三 seed 上把准确率稳定在 Full 附近, 安全性结果 不依赖某一个 seed。
2. 当前成本瓶颈已经从“主轨迹停不下来”转为“probe 读出本身太贵”。Conservative 的主推理确实缩短, 但被周期性 probe 完全抵消。
3. Persistence 提供最大安全增益, Schema 提供最高性价比; 后续优化应优先减少读出 频率或复用读出, 而不是在这三个 seed 上放宽已冻结的安全阈值。

若继续按原协议推进, 优先级应是: 先补 Qwen3-8B 的 3 seed 完整流, 再执行两条 CertIndex 独立基线, 最后重新聚合 submission gate。任何基于本报告现象设计的稀疏 probe、adaptive probe 或新 Governor 规则, 都应标为 post-hoc, 并在新注册的 seed 或数据集上验证。

9 复现索引

- 冻结协议: benchmark/FalseConsensus/final_eval/protocol.json
- 三 seed 结果: benchmark/FalseConsensus/results/final_eval/deepseek7b_math500/
- 聚合主表: benchmark/FalseConsensus/results/final_eval/aggregate/model_seed_aggregate.csv
- 逐 seed 表: benchmark/FalseConsensus/results/final_eval/aggregate/per_seed_summary.csv
- 机制表: benchmark/FalseConsensus/results/final_eval/aggregate/mechanism_per_seed.csv
- Gate: benchmark/FalseConsensus/results/final_eval/aggregate/submission_gate.json
- 聚合代码: benchmark/FalseConsensus/final_eval/aggregate_runs.py
- 报告制图: benchmark/FalseConsensus/report/make_final_eval_report_figures.py

本轮执行提交范围为 85f991a 至 1ec2525, 分支 final-eval-multiseed, 远端已同步至 origin/final-eval-multiseed。