

False Consensus in Adaptive Reasoning —Stage 1-5 实验报告

Understanding False Consensus: Agreement 是不是 Correctness?

2026-07-22

目录

1	执行摘要	2
2	背景与实验设置	2
2.1	研究问题	2
2.2	设置（全部固定，按 plan.md）	2
2.3	数据集规模（Stage 1 产出）	3
3	Stage 2: Agreement vs Accuracy	3
3.1	校准表	3
4	Stage 3: False Consensus 案例与分类	4
4.1	案例导出	4
4.2	分类（Type A-E）	6
5	Stage 4: 轨迹分析——信念何时形成、是否翻盘	6
5.1	共识形成时间 vs 准确率	6
5.2	Recovery（翻盘）	7
6	Stage 5: Consensus Reliability 与 Governor 模拟	7
6.1	可靠性指标	7
6.2	Governor 早停模拟（在同一份 log 上离线回放）	7
7	数据质量与评估修正（影响复现）	9
8	对 Governor++ 的启示与下一步	9
9	附录：产出物与复现	9
9.1	文件清单（benchmark/FalseConsensus/）	9
9.2	复现命令	9

1 执行摘要

本报告是 False Consensus 项目 (plan.md) Stage 1-5 的首轮完整结果。我们在 **MATH500** 全部 **500** 题上, 用 **DeepSeek-R1-Distill-Qwen-7B** 以纯记录模式 (Governor 不做任何干预) 沿单条推理轨迹每 128 tokens 打一次探针 (probe), 共记录 **8,739** 个 **probe**, 然后离线分析 agreement 与 accuracy 的关系。

核心结论: **Agreement** 不等于 **Correctness**, 且”差多少”取决于在哪里测 **agreement**。

1. 全轨迹完美共识几乎可信: 从第一个 probe 到最后全部一致 (cumulative share = 1, 非空答案) 的 87 题中准确率 98.9%, 真正的全程假共识只有 1 例。
2. **Governor** 在线看到的”窗口共识”不可信: 最后 5 个 probe 一致的 338 题中 准确率只有 93.5%, **22 例 (6.5%)** 为 **false consensus**。
3. **False consensus** 的真实代价在早停: 模拟 Dynasor 式早停 (连续 3 个 probe 一致即停) 会在 416/500 题触发, 停机答案准确率 **69.2%**, 而同批题 继续推理到底可达 **85.6%** ——损失 16.4 个百分点, 换取平均 1,321 tokens 节省; **128** 题停在错误答案上。
4. 翻盘极其普遍: 第一个 probe 答错的 375 题中 **76.3%** 最终答对; 145 题 曾形成与最终答案不同的”假稳定共识”, 其中 65.5% 最终改对。早停会系统性地 杀死这些翻盘。
5. 共识形成越晚越不可信: <512 tokens 内形成共识的题准确率 87.4%, >2048 tokens 才形成的仅 58.1% ——与 plan 中”越早形成越容易错”的猜想方向相反。
6. 方法论发现: 约 1/5 的早停错误源于 **probe** 格式伪影 (非选择题却稳定 输出”B”/”D”等选项字母); 6.3% 的 probe 答案为空 (答案太长装不下 10 个 probe token)。这两类信号都不是模型的真实信念, Governor++ 必须过滤。

2 背景与实验设置

2.1 研究问题

Governor/Dynasor 用 probe 之间的一致性 (certainindex) 作为提前停止推理的依据, 隐含假设是 **Agreement** $\approx$ **Correctness**。本项目第一阶段的任务就是检验这个假设: 模型能稳定形成一致意见、却仍然给出错误答案 (false consensus) 的情况有多少、长什么样、什么时候发生。

2.2 设置 (全部固定, 按 plan.md)

项目	取值
模型	DeepSeek-R1-Distill-Qwen-7B (vLLM 0.x, 1×A100-80G, prefix caching)
数据集	MATH500 全部 500 题
Token budget	3072
Probe 间隔	128 tokens (每题最多 24 个 probe)
Probe 文本	**Final Answer** \n\n[\boxed{, 最多 10 tokens
采样	temperature 0.6, top_p 0.95, seed 42
Governor	关闭 (无 early stop / upgrade / decision, 只记录)

每题生成一条推理轨迹: 生成 128 tokens → 打 probe 提取当前答案 → 继续生成 → ……直到自然结束或耗尽 budget。答案等价性用 Dynasor 的 **math_equal** 分组。

2.3 数据集规模 (Stage 1 产出)

指标	数值
题目数	500
Probe 总数 (CSV 行数)	8,739
空 probe 答案	553 (6.3%, 多为答案过长装不下)
在 budget 内自然结束	309 题 (61.8%)
平均消耗 tokens	2,275
最终准确率	81.2%

产出文件: `probes.csv` (每 probe 一行: `problem_id`、`token_position`、`probe_id`、`probe_answer`、`share`、`entropy`、`unique_answers`、`dominant_answer`、`is_certain`、`reasoning`、`final_answer`、`final_correct`) + `traj/` (500 条完整轨迹 JSON)。

3 Stage 2: Agreement vs Accuracy

我们报告两种 agreement 定义:

- **Cumulative share** (plan.md 定义): 整条轨迹所有 probe 中多数答案的占比。注意 probe 数少时该值平凡地偏高 (只有 1 个 probe 时恒为 1)。
- **Window share**: 最后 5 个 probe 中非空答案的多数占比——这是 Governor 在线决策时真正看得到的信号。

3.1 校准表

Cumulative share (全轨迹):

share 区间	n	平均 share	准确率
<0.5	113	0.349	55.8%
0.5-0.6	61	0.538	77.0%
0.6-0.7	55	0.643	89.1%
0.7-0.8	87	0.747	86.2%
0.8-0.9	60	0.845	95.0%
0.9-<1	29	0.923	79.3%
=1.0	95	1.000	95.8% (排除空串共识后 87 题 98.9%)

Window share (最后 5 个 probe):

share 区间	n	平均 share	准确率
<0.5	40	0.376	27.5%
0.6-0.7	45	0.604	66.7%
0.8-0.9	36	0.800	47.2%
=1.0	338	1.000	93.5%

两个要点: (1) agreement 与 accuracy 总体单调正相关, certainindex 的方向性没错; (2) 但 **share=1** 也不等于 **100%** 正确, 且窗口 share 在 0.8-0.9 段严重高估 可信度 (标称 80% 一致, 实际只有 47.2% 正确) ——false consensus 成立。




图 1: Figure 1 · Agreement vs Accuracy (cumulative share)

4 Stage 3: False Consensus 案例与分类

4.1 案例导出

三类 false consensus 共导出 **134** 个案例 (`false_consensus_cases.json/.md`):

类型	定义	数量
全程假共识	cumulative share=1 (非空) 且答错	1
窗口假共识	最后 5 probe 一致且答错	22
早停假共识	Dynasor 式停机点答案错误	128

唯一的全程假共识 (**P456**): 求 $f(n) = n$ 的所有整数解, 正确答案 -2, 1。24 个 probe 从头到尾全部回答 1 ——模型从未考虑过第二个根。这是最纯粹的 false consensus: 完美一致、完全稳定、部分错误 (漏根)。

典型窗口假共识 (**P46**): 求最小的 n 使 $z^4 + z^2 + 1 = 0$ 的根都是 n 次单位根, 正确答案 6。模型前 5 个 probe 都正确地回答 6, 随后“想多了”改成 12 并在其余 19 个 probe 里稳定坚持——正确的早期信念被推理过程自己推翻 (overthinking)。




图 2: Figure 1b · Agreement vs Accuracy (last-5 window share)




图 3: Figure 2 · Agreement 分布: 63.9% 的题最终窗口完全一致, cumulative share 也在 1.0 处聚集

4.2 分类 (Type A-E)

对前 100 题的 28 个早停错误案例逐案人工分类 (AI 辅助初分类, 明细与每案理由 在 `classify_cases.py`, 供复核修改):

Type	含义	数量	占比
A	数字坍塌: 稳定收敛到错误数字 (算术/推导滑坡)	14	50%
D	推导遗漏: 漏根 / 漏 case / 未验根 / 审错题	7	25%
E	格式伪影: 非选择题稳定输出“B”/“D”等字母	6	21%
B	表达式坍塌: 错误化简 (如 $\cot x \rightarrow 0$)	1	4%
C	符号错误	0	0%

Figure 3 · False consensus types (n=28)




图 4: Figure 3 · False consensus 类型分布 (n=28, 前 100 题)

Type E 值得单独强调: 概率题 P75 (求乘积是 5 的倍数的概率, 答案 11/36) 的 probe 序列是 B, B, A, B, A, B, B, D, ...——模型在推理中途被 probe 打断时, 会幻觉出一个选择题的选项体系并稳定地“选”某个字母。这类“共识”与模型对数学 答案的信念无关, 是 **probe** 机制自身的伪影, 占早停错误的约 1/5。任何基于 probe agreement 的控制器都应先过滤此类答案形态。

5 Stage 4: 轨迹分析——信念何时形成、是否翻盘

5.1 共识形成时间 vs 准确率

共识时间 = 窗口 share 首次 ≥ 0.8 (至少 3 个 probe) 的 token 位置:

共识形成时间	n	最终准确率
<512 tokens	143	87.4%
512-1024	112	84.8%
1024-1536	106	89.6%

共识形成时间	n	最终准确率
1536-2048	43	79.1%
>2048	31	58.1%
从未形成	65	—

结论与 **plan** 的猜想相反：不是“越早形成越容易错”，而是越晚形成越不可信。解释：能快速收敛的多是模型有把握的简单题；拖到 2048+ tokens 才勉强一致的，多是能力边界上的难题，其“共识”质量本身就差。

5.2 Recovery（翻盘）

- **145** 题（29%）曾形成过与最终答案不同的 3-probe 稳定共识；其中 **95** 题（**65.5%**）最终改成了正确答案。“稳定”远不是“终局”。
- **Initial belief**: probe 1 就答对的只有 125/500（25%）。probe 1 答错的 375 题中，**286** 题（**76.3%**）最终翻盘答对。

这两个数字共同说明：推理轨迹中的中期共识有很大概率被后续推理修正，任何在共识首次出现就停止的策略，都在系统性地没收翻盘的机会。

6 Stage 5: Consensus Reliability 与 Governor 模拟

6.1 可靠性指标

$$CR(s) = P(\text{correct} \mid \text{share} = s)$$

指标	数值
CR(cumulative share=1)	0.989
CR(window share=1)	0.935
Consensus Calibration Error (cumulative, 加权)	0.149
Consensus Calibration Error (window, 加权)	0.080

6.2 Governor 早停模拟（在同一份 log 上离线回放）

停机规则（Dynasor-CoT 默认思路）：连续 3 个 probe 答案一致、非空、且 probe 输出不含犹豫词（wait/but/hmm...）即停止。

指标	数值
触发停机	416/500 题（83.2%）
停机答案准确率	69.2%
同批题跑到底的准确率	85.6%
准确率损失	16.4 个百分点
平均节省 tokens（停机题）	1,321（约 43% budget）
停在错误答案上	128 题

这就是 false consensus 的实际价格：以现行的“一致即停”，每 3.25 个停机就有 1 个停在错误答案上。




图 5: Figure 4 · 共识形成时间 vs 准确率




图 6: Figure 5 · Consensus reliability: 橙线为标称 agreement, 蓝柱为实际 P(correct), 差值即校准误差

7 数据质量与评估修正（影响复现）

分析中发现并修正了三类上游评估问题（均已在 `analyze.py` 处理，logging 原始数据不受影响）：

1. `strip_string` 吞掉 `\text{...}`：P97 参考答案 `\text{east}` 被剥成空串，模型答对被判错。
修正：对 raw / stripped / unwrap 三种形态分别匹配。
2. 超长答案的空 `probe` 假共识：P179（平面方程）、P408（向量）的答案装不进 10 个 probe token，所有 probe 为空串，空串“一致”曾被计为完美共识。修正：一致性统计只认非空答案（窗口至少 3 个非空）。
3. `math_equal` 不认 `x\in[-2,7]` 与 `[-2,7]` 等价（P383）。修正：剥 `x\in` 前缀后再比较。

这些修正合计影响约 1% 的判分，但恰好集中在 share=1 的关键区间——若不修正，“全程假共识”会被高估 4 倍（4 例 vs 实际 1 例）。

8 对 Governor++ 的启示与下一步

Stage 6 的设计原则应为 **Stop = Agreement AND Reliable**，本轮数据直接支持以下 Reliable 信号（全部可在现有 log 上离线回放验证，无需重跑模型）：

1. 答案形态过滤：字母型答案（Type E）与空串不计入共识——立刻消掉约 1/5 的错误停机；
2. 共识时间：晚于 ~2048 tokens 才形成的共识不可信（58.1%），不应触发早停；
3. 窗口强度：3-probe 窗口过于激进；加大窗口 / 提高门槛 / 要求熵持续下降；
4. 轨迹稳定性：历史上换过答案的轨迹（145 题）局部一致也不可靠，应要求更长的稳定期。

下一步（对应 plan Week 3+）：

- 人工复核 28 例分类；对 500 题的 134 例做全量分类；
- Governor++ 原型：离线回放不同 stop 规则，画 accuracy-token Pareto 前沿；
- 多模型（Qwen、Llama distill）与多数据集（GSM8K / AIME24 / AMC23）复制本流程——脚本已参数化，换 `--model` / `--dataset` 即可。

9 附录：产出物与复现

9.1 文件清单（`benchmark/FalseConsensus/`）

文件	内容
<code>logging_run.py</code>	Stage 1 纯记录模式（可断点续跑）
<code>analyze.py</code>	Stage 2-5 分析与全部图表
<code>classify_cases.py</code>	Stage 3 分类（含逐案理由）与 pie chart
<code>FINDINGS.md</code>	结果总结
<code>results/stage1_logging/probes.csv</code>	8,739 行 probe 记录
<code>results/stage1_logging/traj/</code>	500 条完整轨迹
<code>results/stage1_logging/analysis/</code>	500 题分析：figures + report.md + 案例导出
<code>results/stage1_logging/analysis_n100/</code>	前 100 题存档（含分类）

9.2 复现命令

```
# 服务器（~/Governor, venv ~/fc-venv, 模型已在 HF cache）
bash ~/fc_launch.sh                # 起 vLLM (GPU 7) + logging (tmux)
```

```
python analyze.py --input results/stage1_logging  
python classify_cases.py results/stage1_logging/analysis_n100
```

实验于 2026-07-22 完成；500 题 logging 全程约 21 分钟（单卡 A100，16 并发）。