

False Consensus in Adaptive Reasoning —Stage 11-12 跨模型/跨数据集 + Probe 消融报告

结论能否泛化？换模型、换数据集、换 probe 措辞的三组验证

2026-07-24

目录

1	执行摘要	3
1.1	先厘清几个容易混淆的量	3
1.2	六条主要发现	3
2	背景与实验设置	4
2.1	研究问题	4
2.2	三组实验的设置	4
2.3	数据集规模与整体结果	5
3	实验 A：跨模型验证 (Qwen3-8B × MATH500)	5
3.1	Agreement vs Accuracy	5
3.2	轨迹分析：共识时间与翻盘	6
3.3	Consensus Reliability 与 Governor 早停模拟	7
4	实验 B：跨数据集验证 (DeepSeek-7B × AMC23 / AIME24)	7
4.1	AMC23 (40 题，整体准确率 60.0%)	7
4.2	AIME24 (30 题，整体准确率 26.7%，最难切片)	8
5	实验 C：Probe 措辞消融 (Certainindex 顿悟前缀)	8
5.1	与基线的直接对比	8
5.2	Governor 早停：最值得注意的差异	10
6	横向对比与总结	11
6.1	汇总表	11
6.2	可靠性指标汇总	12
6.3	三条主结论	12
7	方法学与数据质量注记	12
8	对 Governor++ 的启示与下一步	12
9	附录：产出物与复现	13
9.1	文件清单	13

9.2 复现命令	13
--------------------	----

1 执行摘要

本报告是 False Consensus 项目 Stage 1-5 首轮结论 (report/report.md, DeepSeek-R1-Distill-Qwen-7B $\times$ MATH500 $\times$ 500 题) 的泛化性验证, 用完全相同的 纯记录 + 离线分析流程 (logging_run.py / analyze.py, 仅换 --model / --dataset / --probe-suffix-style) 跑了三组实验:

- 实验 A (Stage 11, 跨模型): Qwen3-8B $\times$ MATH500 $\times$ 500 题;
- 实验 B (Stage 12, 跨数据集): DeepSeek-7B $\times$ AMC23 (40 题)、AIME24 (30 题);
- 实验 C (Probe 消融): DeepSeek-7B $\times$ MATH500 $\times$ 500 题, 把 probe 后缀从裸的 ****Final Answer**** \boxed{ 换成 Certainindex 式”顿悟”前缀 ... Oh, I suddenly got the answer to the whole problem, ****Final Answer**** \boxed{。

核心结论: Stage 1-5 的诊断不是单一模型/数据集/probe 措辞的伪影——换模型、换数据集都稳定复现, 且 probe 措辞会实质影响早停信号的可靠性。

1.1 先厘清几个容易混淆的量

本报告反复出现三种”准确率”, 分母不同, 务必分清 (详见第 7 节):

术语	含义	分母
整体准确率	整个数据集所有题、最终答案答对的比例 (系统总分)	全部题
停机答案准确率	假设用”3-probe 一致即停”规则, 在会触发停机的那批题上, 按停机瞬间的答案算对错	会停机的子集
同批到底准确率	还是那批会停机的题, 但不停、让它跑到底, 最终答对的比例	会停机的子集

- 早停的准确率代价 = 同批到底准确率 - 停机答案准确率 (在同一子集上比较, 越大越亏)。
- 关键陷阱: 后两者的分母都是”会停机的子集”, 不是整个数据集——例如实验 A 的”同批到底 89.7%”是 340 道会停机的题的数字, 该模型的整体准确率其实只有 78.2%, 两者不可混用。
- 另外两个量: 校准曲线/表的纵轴是最终答案准确率; 而 false consensus (假共识) 计数看的是探针窗口那个一致答案本身对不对 (窗口一致但答错), 二者可差几个点, 差值即”窗口曾错、后续翻对”的题。

1.2 六条主要发现

1. 跨模型稳健 (实验 A): Qwen3-8B 上 window share=1 (最后 5 个探针全一致) 的 372 题里, 那个一致答案只有 89.0% 是对的, 即 41 例 (11.0%) 是假共识——比 DeepSeek 的 6.5% 还高。“局部一致 $\neq$ 终局正确”在另一个模型上不仅复现, 量级还更明显。
2. 早停代价跨模型一致 (实验 A): 3-probe 一致即停会在 340/500 题触发; 这批题 停机就交卷只有 83.5% 对, 放它们跑完能到 89.7% ——早停白白亏掉 6.2 个百分点, 56 题停在了错误答案上, 平均省 1,306 tokens。
3. 翻盘依旧普遍 (实验 A): 第一个探针就答错的 371 题里, 72.2% 最终自己翻盘 答对; 161 题曾形成异于终答的稳定共识, 其中 108 题 (67.1%) 最终改对——早停会 系统性没收这些翻盘。与 DeepSeek 高度一致。
4. 难数据集放大早停风险 (实验 B): AMC23 整体准确率 60.0%、AIME24 仅 26.7%; AIME24 上早停亏掉 26.6 个百分点 (停机 26.7% vs 跑完 53.3%), 且无一题在 budget 内自然收尾、全程完美共识从未出现。小样本 (30-40 题) 方差大, 取方向性。

5. **Probe** 措辞是早停可靠性的旋钮（实验 C，最值得注意）：把探针后缀从裸的 `\boxed{}` 换成 `Certainindex` 式“我突然想到了答案”前缀，整体准确率几乎不变（79.6% vs 81.2%），但同一条早停规则白白亏掉的准确率从 **16.4pp** 缩到 **1.3pp**，错误停机从 128 题降到 35 题（详见第 5 节的逐字解释）。代价是触发更保守、停得更晚、省的 token 减半。单 seed 观察，待受控复跑确认。
6. 可视化速览：图 1 用一张图讲清“每组实验早停到底亏多少准确率”——橙点 = 停机就交卷的准确率，灰点 = 放它跑完的准确率，两点之间的距离就是早停的代价。




图 1: 图 1 · 每组配置里“3-probe 一致即停”规则亏掉的准确率。橙点 = 停机交卷、灰点 = 同批题跑到底；两点距离即早停代价，越宽越亏。DeepSeek · MATH500 (simple probe) 亏 16.4pp、换成 certainindex probe 后只亏 1.3pp；AIME24 最惨，亏 26.6pp。

2 背景与实验设置

2.1 研究问题

Stage 1-5 在 DeepSeek-7B × MATH500 上得到一组诊断性结论：agreement 与 correctness 正相关但 **local agreement** ≠ **terminal correctness**，Dynasor 式“一致即停”会系统性地损失准确率并没收翻盘。一个自然的质疑是：这些结论是不是 只对这一个模型、这一个数据集、这一种 **probe** 措辞成立？本报告用三组受控替换 回答这个问题。

2.2 三组实验的设置

除下表标注的替换项外，其余参数与 Stage 1 完全一致 (budget 3072、probe 间隔 128 tokens、probe max 10 tokens、temperature 0.6、top_p 0.95、seed 42、Governor 关闭仅记录、答案等价性用 `math_equal` 分组)。

实验	模型	数据集	Probe 后缀	题数
基线 (Stage 1-5)	DeepSeek-R1-Distill-Qwen-7B	MATH500	simple	500
A (Stage 11)	Qwen3-8B	MATH500	simple	500

实验	模型	数据集	Probe 后缀	题数
B (Stage 12)	DeepSeek-R1-Distill-Qwen-7B	AMC23 / AIME24	simple	40 / 30
C (Probe 消融)	DeepSeek-R1-Distill-Qwen-7B	MATH500	certainindex	500

两种 probe 后缀 (logging_run.py 中 PROBE_SUFFIXES):

- **simple** (Stage 1-8): ****Final Answer**\n\n\[\boxed{**
- **certainindex** (实验 C) : ... Oh, I suddenly got the answer to the whole problem, ****Final Answer**\n\n\[\boxed{**

两者的 probe 生成上限都是 10 tokens; 差别只在续写前缀是否带一句”顿悟”式的 提交诱导语——这正是 Dynasor/Certainindex 论文里 probe 的实际写法。

2.3 数据集规模与整体结果

指标	基线 (DS/MATH)	A (Qwen/MATH)	B1 (DS/AMC23)	B2 (DS/AIME24)	C (DS/MATH · CI)
题数	500	500	40	30	500
Probe 记录数	8,739	10,679	836	720	8,736
空 probe 答案	6.3%	7.6%	0.2%	0.7%	5.8%
budget 内自然结束	61.8%	35.0%	37.5%	0.0%	60.8%
整体准确率	81.2%	78.2%	60.0%	26.7%	79.6%

(DS = DeepSeek-7B, CI = certainindex probe。)Qwen3-8B 生成更长 (自然结束率仅 35%, probe 记录多出 22%); AIME24 无一题在 3072 token budget 内自然收尾, 说明 现行 budget/probe 协议在能力边界处已被压满。

3 实验 A: 跨模型验证 (Qwen3-8B × MATH500)

3.1 Agreement vs Accuracy

Cumulative share (全轨迹):

share 区间	n	平均 share	最终准确率
<0.5	70	0.378	51.4%
0.5-0.6	58	0.538	65.5%
0.6-0.7	51	0.651	80.4%
0.7-0.8	80	0.748	80.0%
0.8-0.9	81	0.848	87.7%
0.9-<1	64	0.941	89.1%
=1.0	96	1.000	87.5%

Window share (最后 5 个 probe):

share 区间	n	平均 share	最终准确率
<0.5	14	0.356	21.4%
0.5-0.6	5	0.500	40.0%
0.6-0.7	30	0.613	46.7%
0.7-0.8	7	0.750	42.9%
0.8-0.9	43	0.800	58.1%
=1.0	372	1.000	90.1%

- cumulative share=1 (非空): 88 题, 窗口答案准确率 92.0%, **false consensus 7**;
- window share=1: 372 题, 窗口答案准确率 **89.0%**, **false consensus 41 (11.0%)**。

(说明: window 表最后一行的 90.1% 是这 372 题的最终答案准确率; FC 计数用的是 窗口共识答案本身的准确率 89.0%, 两者的 1.1pp 差即窗口错、但后续翻对的少数题。)

结论与 Stage 1 完全同向: agreement 与 accuracy 单调正相关 (certaindex 方向没错), 但 **share=1** 不等于 **100%** 正确, 且 Qwen3-8B 的窗口假共识比例 (11.0%) 比 DeepSeek (6.5%) 更高——更强的一致性倾向反而带来更多“自信的错误共识”。图 2 把 DeepSeek 与 Qwen3-8B 两个模型的校准曲线叠在同一张图上: 两条线形状几乎一致, Qwen 整体略低, 且在窗口 share 中段 (右图) 低于对角线更明显。




图 2: 图 2 · 两个模型在 MATH500 上的 agreement-accuracy 校准 (纵轴为最终准确率, 点面积 $\propto \sqrt{n}$)。左: 全轨迹 cumulative share; 右: 最后 5 探针的 window share, 即 Governor 在线看到的信号。

3.2 轨迹分析: 共识时间与翻盘

共识形成时间 (window share 首次 ≥ 0.8) vs 最终准确率:

共识形成时间	n	最终准确率
<512 tokens	197	78.7%
512-1024	136	86.8%
1024-1536	82	81.7%
1536-2048	39	76.9%

共识形成时间	n	最终准确率
>2048	20	55.0%
从未形成	26	—

“越晚形成越不可信”在 Qwen3-8B 上继续成立：>2048 tokens 才勉强一致的题准确率 只有 55.0% (Stage 1 为 58.1%)。

- **Recovery**: 161 题曾形成异于最终答案的 3-probe 稳定共识，其中 **108 题 (67.1%)** 最终改对；
- **Initial belief**: probe 1 答对仅 129/500；probe 1 答错的 371 题里 **268 题 (72.2%)** 最终翻盘答对。

翻盘的普遍程度与 DeepSeek (76.3%) 几乎一致——任何”共识首现即停”的策略都会在 Qwen3-8B 上同样系统性地没收翻盘。

3.3 Consensus Reliability 与 Governor 早停模拟

指标	数值
CR(cumulative share=1)	0.920
CR(window share=1)	0.890
Consensus Calibration Error (cumulative)	0.092
Consensus Calibration Error (window)	0.118

早停规则同 Stage 5 (连续 3 probe 一致、非空、确定即停)：

指标	数值
触发停机	340/500 题 (68.0%)
停机答案准确率	83.5%
同批题跑到底准确率	89.7%
准确率损失	6.2 个百分点
平均节省 tokens (停机题)	1,306
停在错误答案上	56 题

(CR、CCE 的跨实验对比见第 6 节汇总表；早停代价的可视化见图 1。)

4 实验 B：跨数据集验证 (DeepSeek-7B × AMC23 / AIME24)

两个数据集样本量小 (40 / 30 题)，单个 bin 常只有个位数样本，下列数字方差大，只作方向性证据。

4.1 AMC23 (40 题，整体准确率 60.0%)

Window share (最后 5 个 probe)：

share 区间	n	平均 share	最终准确率
<0.5	8	0.325	12.5%

share 区间	n	平均 share	最终准确率
0.6-0.7	3	0.600	0.0%
0.8-0.9	4	0.800	0.0%
=1.0	25	1.000	92.0%

- cumulative share=1: 3 题, 准确率 100.0%, false consensus 0;
- window share=1: 25 题, 窗口答案准确率 92.0%, **false consensus 2 (8.0%)**。
- Recovery: 10 题曾异于终答的稳定共识 (4 题改对); probe 1 答对 8/40, 答错的 32 题中 18 题 (56.2%) 翻盘。
- Governor 早停: 31/40 触发, 停机准确率 **67.7%** vs 同批到底 **74.2%** (损失 6.5pp), 平均省 1,412 tokens, **10** 题停在错误答案上。
- 可靠性: CR(cum=1)=1.000, CR(win=1)=0.920, CCE cum/win = 0.210 / 0.215。

4.2 AIME24 (30 题, 整体准确率 26.7%, 最难切片)

Window share (最后 5 个 probe):

share 区间	n	平均 share	最终准确率
<0.5	15	0.293	0.0%
0.6-0.7	1	0.600	0.0%
0.7-0.8	1	0.750	0.0%
0.8-0.9	4	0.800	25.0%
=1.0	9	1.000	77.8%

- cumulative share=1: **0** 题 (全程完美共识从未出现, CR(cum=1)=nan);
- window share=1: 9 题, 窗口答案准确率 77.8%, **false consensus 2 (22.2%)** ——一致窗口里每 4.5 个就有 1 个是错的, 是所有实验里 FC 比例最高的;
- Recovery: 12 题曾异于终答的稳定共识 (5 题改对); probe 1 答对 **0/30** (最难题上首个 probe 全是被迫猜测), 答错的 30 题中 8 题 (26.7%) 翻盘;
- Governor 早停: 15/30 触发, 停机准确率 **26.7%** vs 同批到底 **53.3%** (损失 **26.6pp**), 平均省 1,323 tokens, **11** 题停在错误答案上;
- 可靠性: CR(win=1)=0.778, CCE cum/win = 0.071 / 0.332 (window 校准误差是所有实验里最大的)。

跨数据集结论: 难度越高, 早停越危险。在模型能力边界处 (AIME24), probe 共识的校准彻底崩坏——一致窗口里 22.2% 是错的, 早停直接损失 26.6pp。这与“越晚/越难形成的共识越不可信”的机制解释一致, 也说明 Governor++ 的 validity filter 必须随数据集难度自适应, 不能用 MATH500 上标定的固定阈值。

5 实验 C: Probe 措辞消融 (Certainindex 顿悟前缀)

同模型、同数据集、同 500 题, 仅把 probe 后缀换成带“顿悟”提交诱导语的 **certainindex** 风格, 直接对照 Stage 1 基线。

5.1 与基线的直接对比




图 3: 图 3 · 共识形成越晚越不可信（两模型叠加）：window 共识首次形成的 token 位置 vs 最终准确率。>2048 tokens 才勉强一致的题，两模型都跌到 55-58%。




图 4: 图 4 · 难度放大失准（DeepSeek，三数据集的 window-share 校准叠加，纵轴为最终准确率）。MATH500（蓝）在 window 一致时仍有 ~94% 正确；AMC23（绿）与 AIME24（红）在同样“完全一致”处分别只有 ~92% 和 ~78%，且低 share 段几乎贴地。小样本，点稀疏属正常。

指标	基线 (simple)	实验 C (certaindex)	差异
整体准确率	81.2%	79.6%	-1.6pp
budget 内自然结束	61.8%	60.8%	-1.0pp
空 probe 率	6.3%	5.8%	-0.5pp
window share=1 题数	338	336	≈ 持平
window share=1 准确率	93.5%	89.6%	-3.9pp
window share=1 中 false consensus	22 (6.5%)	35 (10.4%)	+3.9pp

Window share 校准表 (certaindex):

share 区间	n	平均 share	最终准确率
<0.5	43	0.353	44.2%
0.5-0.6	5	0.500	80.0%
0.6-0.7	41	0.605	61.0%
0.7-0.8	10	0.750	80.0%
0.8-0.9	35	0.800	57.1%
=1.0	336	1.000	90.2%

5.2 Governor 早停：最值得注意的差异

指标	基线 (simple)	实验 C (certaindex)
触发停机	416/500	311/500
停机答案准确率	69.2%	88.7%
同批题跑到底准确率	85.6%	90.0%
准确率损失	16.4pp	1.3pp
平均节省 tokens	1,321	683
停在错误答案上	128 题	35 题

5.2.1 “16.4pp 降到 1.3pp”到底指什么

这句话说的是同一条早停规则、在两种 **probe** 措辞下，各自白白亏掉多少准确率，逐字拆开：

- 在 **simple probe** 下，规则会在 416 题上触发停机。这 416 题如果停机就交卷，只有 **69.2%** 对；如果放它们跑到底，能有 **85.6%** 对。停机比跑完低了 $85.6 - 69.2 = 16.4$ 个百分点——这就是早停在 simple probe 下付出的准确率代价。
- 在 **certaindex probe** 下，规则改为在 311 题上触发。这 311 题停机交卷 **88.7%** 对、跑到底 **90.0%** 对，两者只差 $90.0 - 88.7 = 1.3$ 个百分点。

也就是说：换一句 probe 措辞，“早停”这个动作从“平均每次亏 16.4pp”变成“几乎不亏 (1.3pp)”，错误停机从 128 题降到 35 题 (-73%)。注意这两个“损失”都是在各自会停机的子集内比较的（分母 416 vs 311，见第 1 节概念表），不是在说整体准确率变化——整体准确率其实几乎没动 (81.2% → 79.6%)。代价则是：certaindex 触发更保守 (311 < 416)、停得更晚，平均只省 683 tokens (约 simple 的一半)。

解释（谨慎）：带“顿悟”前缀的 probe 似乎让模型只在推理确有进展时才提交一个 稳定答案，从而“3-probe 一致”这个信号更能反映真实信念——这正是 Stage 1 提出的“Stop = Agreement AND Reliable”

里 **Reliable** 分量被 **probe** 措辞增强的直接证据。但需注意：这是单 seed 结果，更低的 token 节省部分来自更高的自然结束率（可省空间 本就更小）；且 window share=1 的假共识比例反而略升（10.4% vs 6.5%），说明 certainindex probe 改善的是早停规则的选择性（该停才停），而非消除窗口假共识本身。应做一次预算/温度对齐的受控复跑再下强结论。




图 5: 图 5 · 探针措辞对校准的影响很小（DeepSeek · MATH500，window-share 校准，纵轴为最终准确率）。simple（蓝）与 certainindex（紫）两条线基本重合——措辞主要改变的是早停规则的触发时机与选择性（图 1），而非 agreement-accuracy 关系本身。

6 横向对比与总结

6.1 汇总表

实验	模型 / 数据集	n	整体准确率	win=1 题数	其中 FC	Governor 触发	停机 vs 同批到底	省 tokens	错误停机
基线	DS / MATH500	500	81.2%	338	22 (6.5%)	416/500	69.2% / 85.6%	1,321	128
A	Qwen3-8B / MATH500	500	78.2%	372	41 (11.0%)	340/500	83.5% / 89.7%	1,306	56
B1	DS / AMC23	40	60.0%	25	2 (8.0%)	31/40	67.7% / 74.2%	1,412	10
B2	DS / AIME24	30	26.7%	9	2 (22.2%)	15/30	26.7% / 53.3%	1,323	11
C	DS / MATH500 · CI	500	79.6%	336	35 (10.4%)	311/500	88.7% / 90.0%	683	35

6.2 可靠性指标汇总

实验	CR(cum=1)	CR(win=1)	CCE(cum)	CCE(win)
基线	0.989	0.935	0.149	0.080
A (Qwen)	0.920	0.890	0.092	0.118
B1 (AMC23)	1.000	0.920	0.210	0.215
B2 (AIME24)	nan	0.778	0.071	0.332
C (certaindex)	0.936	0.896	0.132	0.100

6.3 三条主结论

1. 诊断跨模型、跨数据集成立：window share=1 从来不是 100% 正确（89.0%–92.0% 在 MATH/AMC, AIME 上更低到 77.8%），Governor 式早停在每一组里都损失准确率并 停在错误答案上。Stage 1-5 的核心发现不是 DeepSeek/MATH500 的特例。
2. 难度是放大器：从 MATH500 (FC 约 11%、早停损失 6pp) 到 AIME24 (FC 22%、早停 损失 27pp)，越靠近模型能力边界，probe 共识越不可信、早停越危险。固定阈值的 停机规则不可跨难度迁移。
3. **probe** 措辞是可调的可靠性旋钮：仅改 probe 续写前缀 (certaindex 顿悟语)，就能把同一早停规则的准确率损失从 16.4pp 降到 1.3pp、错误停机减少 73% ——说明“让 probe 更忠实地反映真实信念”是一条独立于聚合/阈值之外、可直接提升早停安全性 的路径（单 seed，待受控确认）。

7 方法学与数据质量注记

1. “同批到底”≠“整体准确率”：所有 Governor 模拟里的”同批题跑到底准确率”(A=89.7%、B1=74.2%、B2=53.3%、C=90.0%) 都只在该实验触发停机的子集上计算，分母是停机题数 (340/31/15/311)，不是整个数据集。整体准确率见汇总表首列 (78.2% / 60.0% / 26.7% / 79.6%)。两者切勿混用。
2. 小样本警示：实验 B 的 AMC23 (40) 与 AIME24 (30) 单 bin 常仅个位数样本，逐 bin 准确率 (如 AMC23 “1536–2048 tokens 100%”) 不可当作稳定估计，只用于 趋势判断。
3. 单 **seed**：全部三组均为单 seed (seed 42)、单模型规模，尚未做多 seed 置信 区间与多模型规模分析 (plan.md §9.1 的第 3+ 个模型、§11 统计规范)。
4. 评估口径：沿用 Stage 1-5 已修正的 `analyze.py` (`\text{}` 剥离、空串不计 共识、`x\in` 前缀归一化)，跨模型/数据集未引入新的判分修正；AIME24 全部触碰 token 上限，其”未自然结束”是 budget 约束而非评估 bug。

8 对 Governor++ 的启示与下一步

本轮把 Stage 1-5 的 **Stop = Agreement AND Reliable** 从”一个模型上的观察”升级为“跨模型/跨数据集的规律”，并新增一条可操作杠杆：

1. **validity filter** 需难度自适应：MATH500 上标定的窗口/阈值在 AIME24 上会严重 高估可信度 (FC 22.2%)；Governor++ 应把数据集难度 (或在线难度代理，如 Stage 9 的 `hit_token_cap / level`) 纳入停机门槛。
2. **probe** 措辞进入设计空间：certaindex 顿悟前缀几乎零成本地把早停损失压到 1.3pp ——probe 文本本身应作为 Governor++ 的一个可调超参，而非固定为 Stage 1 的裸 boxed 续写。
3. 跨模型阈值不可直接搬运：Qwen3-8B 的窗口假共识率 (11.0%) 高于 DeepSeek (6.5%)，同一”3-probe 一致”规则在不同模型上的安全边界不同。

下一步 (对应 plan.md §9.1 / §10.1 / §18)：

- 补 Stage 11 的第 3+ 个模型与多 seed；补 Stage 12 的 GSM8K / GPQA-Diamond；
- 对实验 C 做预算/温度对齐的受控复跑，确认 certainindex probe 的早停增益是否稳健；
- 把三组数据折进 Stage 10 Governor++ 的规则设计（难度自适应 validity filter + probe 措辞超参）。

9 附录：产出物与复现

9.1 文件清单

路径	内容
results/stage11_cross_model/ qwen3_8b_math500/ results/stage12_cross_dataset/ deepseek7b_amc23/ results/stage12_cross_dataset/ deepseek7b_aime24/ results/probe_suffix_ablation/ deepseek7b_math500_certainindex/	实验 A: probes.csv (10,679 行) + 500 轨迹 + analysis/ 实验 B1: probes.csv (836 行) + 40 轨迹 + analysis/ 实验 B2: probes.csv (720 行) + 30 轨迹 + analysis/ 实验 C: probes.csv (8,736 行) + 500 轨迹 + analysis/

每个 analysis/ 目录含 report.md、per_problem.csv、false_consensus_cases.{json,md} 与 fig1/1b/2/4/5*.png。

9.2 复现命令

实验 A: 跨模型

```
python logging_run.py --model Qwen3-8B --dataset math500 \
  --start 0 --end 500 --output results/stage11_cross_model/qwen3_8b_math500
python analyze.py --input results/stage11_cross_model/qwen3_8b_math500
```

实验 B: 跨数据集 (AMC23 / AIME24)

```
python logging_run.py --dataset amc23 --start 0 --end 40 \
  --output results/stage12_cross_dataset/deepseek7b_amc23
python logging_run.py --dataset aime24 --start 0 --end 30 \
  --output results/stage12_cross_dataset/deepseek7b_aime24
```

实验 C: probe 措辞消融

```
python logging_run.py --dataset math500 --start 0 --end 500 \
  --probe-suffix-style certainindex \
  --output results/probe_suffix_ablation/deepseek7b_math500_certainindex
```

实验于 2026-07-24 在 vast.ai 单卡 RTX 5090 (vLLM) 上完成；数据经本地 git fetch + --ff-only merge 合入 main (commit 799e827)。