

False Consensus in Adaptive Reasoning - 五步 Roadmap 阶段报告

从 probe 读出、Pareto 规则到晚共识根因与 Governor++ 决策

2026-07-24

目录

1 执行摘要：我们现在知道了什么	2
2 项目主线：从现象到控制器	3
3 五步 Roadmap 的依赖关系	4
4 Step 1: Probe 忠实度还是保守 timing?	5
5 Step 2 + Step 4: Pareto Sweep 与规则型 Governor++	6
6 Step 3: 晚共识为什么看起来不可靠?	10
7 Step 5: 为什么现在不训练 calibrator	13
8 统一后的 Governor++ 设计原则	13
9 完成度、限制与下一步	14
10 产出物与复现索引	15

1 执行摘要：我们现在知道了什么

总发现：**Agreement** 是有用信号，但不是安全停止条件。可靠的 Governor 必须同时判断答案是否有效、当前共识是否正确、共识是否已经 terminal，以及继续推理是否仍有 recovery 价值。

本轮围绕 plan.md 第 19 节的 teammate 五步 roadmap，得到六条主要结论：

1. **False consensus** 稳定存在且可以跨模型、跨数据集复现。
DeepSeek-7B 在 MATH500 上使用 naive 3-probe 一致即停，会把同批题准确率从 85.6% 降到 69.2%，损失 16.4 个百分点；Qwen3-8B 和 AIME24 也复现同方向风险。
2. **Certainindex probe** 的优势主要不是措辞读得更准，而是停得更晚。
在共同触发的 306 题上，readout 主效应只有 +0.65pp，timing 主效应为 +9.15pp；约 93% 的绝对主效应来自 timing。
3. **simple@32** 是更好的 **probe** 底座。
配合数学闭合 stop 后，它把空答案率从 6.34% 降到 0.60%，同时把平均每次 probe 输出从 9.20 降到 6.43 tokens。更长的上限并不等于更高的实际成本。
4. “晚共识不可靠”主要是难题混杂，不是同题内的轨迹定律。
题间平均 consensus time 翻倍，对应最终正确率平均下降 11.7pp；同一道题内 consensus time 翻倍，则是 +1.9pp 且不显著。晚形成的共识在同题内反而更可能正确、更可能 terminal。
5. 扩宽漏斗后，找到一个更好的保守工作点。
新的五次一致规则在 DeepSeek validation-2 上准确率不变并节省 17.7% tokens；在 matched Qwen simple@32 上准确率点估计下降 1.0pp、节省 32.2%。它比 Stage-7 Conservative v0 多省约 2.5-3.7pp tokens，但 false-stop 也略高，因而是更均衡的 Governor++ 候选，不是“零风险”结论。
6. **Calibrator** 当前不训练。
简单规则已经给出新的可用工作点，仍没有证据表明非线性模型能稳定超过规则；plan.md 第 8.3.0 节的升级 gate 仍不满足。此处 no-go 是实验结论，不是遗漏。

1.1 五步 roadmap 当前状态

步	任务	状态	得到的决策
1	Paired re-probe 2×2	完成	certainindex 优势主要来自 timing；选择 simple@32 作为 sweep 底座
2	Accuracy-compute Pareto sweep	完成	首轮 p3 失败；扩宽漏斗后 p5 level 规则通过 matched Qwen gate
3	Within-problem K-rollout	完成	晚共识下降主要是难度混杂和 token cap；同题内没有负效应

步	任务	状态	得到的决策
4	Rule-based Governor++	选型完成	推荐 p5 + level768/2048 + certain + schema; v0 保留为更保守 fallback
5	轻量 calibrator	Gate: No-go	当前不训练；先做推荐规则的新 seed 确证

2 项目主线：从现象到控制器

2.1 原始问题

Governor/Dynasor 类方法把多个 probe 的一致性作为提前停止依据，隐含假设是：

$$\text{Agreement} \approx \text{Correctness} \approx \text{Safe to stop}.$$

Stage 1-5 首先证明，这三个量必须分开：

概念	它回答的问题	为什么不能混用
Agreement	最近几个 probe 是否互相一致？	只描述内部一致，不保证答案正确
Correctness	当前共识答案是否等价于参考答案？	Governor 停下交卷时直接关心
Terminality	当前答案之后是否还会改变？	当前答对但不 terminal，继续推理仍可能变错
Safe-stop	Correct AND terminal AND valid？	这是控制器真正需要预测的目标

例子。某题在 768 tokens 连续三次回答 12，但继续推理后发现漏掉一个 case，最终改成 6。768 tokens 处的 agreement 很强，却既不 correct，也不 terminal；“一致即停”会没收这次 recovery。

2.2 Stage 1-12 的关键证据

证据	设置	关键结果	含义
基线 logging	DeepSeek-7B / MATH500 / 500 题	最终准确率 81.2%；8,739 probes	建立完整轨迹底座
Naive stop	3-probe 一致即停	69.2% vs 同批到底 85.6%	损失 16.4pp，128 个错误停机
跨模型	Qwen3-8B / MATH500	window share=1 仍有 11.0% 假共识	不是单模型伪影
难数据集	DeepSeek-7B / AIME24	早停损失 26.6pp	能力边界处风险放大
人工 audit	100 个不一致案例	single-letter probe 0% valid	应先过滤 probe 格式伪影




图 1: 多模型/多数据集上的早停准确率代价。橙点为停机答案，灰点为同批题跑到底；两点距离就是 false consensus 的价格。




图 2: 两个模型在 MATH500 上的 agreement-accuracy 校准。窗口共识越强通常越准，但 share=1 仍不等于 100% 正确。

3 五步 Roadmap 的依赖关系

plan.md 第 19 节把下一阶段拆成五步：

1. Step 1 决定 probe 措辞是否提供独立 readout 增益；
2. Step 2 在选定 probe 流上搜索 accuracy-compute Pareto；
3. Step 3 作为独立机制支线，解释 consensus time；
4. Step 4 把 sweep 获胜规则冻结为 Governor++ v1；

5. Step 5 只有在规则确实不够时才训练 calibrator。

Step 2 和 Step 4 几乎是同一个交付物。Rule-based Governor++ 的核心参数正是 sweep 的搜索轴：validity、min_tokens、patience、window/share、历史换答案次数 与难度自适应 floor。Step 2 选出的获胜配置就是 Step 4 的控制逻辑；Step 4 额外负责 冻结配置、held-out/Qwen 验证和工程打包。

4 Step 1: Probe 忠实度还是保守 timing?

4.1 为什么需要 paired 2×2

早期 probe 消融中，certainindex probe 让 naive stop 的准确率从 69.2% 升到 88.7%，但它同时停得更少、更晚。因此，单看最终差异无法回答：

- 是 certainindex 在相同 prefix 上读出了更真实的 belief?
- 还是它只是拒绝在较早时刻 commit，等主推理继续后再停?

实验把四个 cell 全部锁在上一批 simple 主轨迹上，只替换 stop timing 与 readout：

	读 simple 答案	读 certainindex 答案
simple timing	simple 现状	固定早停时刻，只换措辞
certainindex timing	固定晚停时刻，仍读 simple	certainindex 现状

4.2 共同触发集合上的主结果

两个 timing 规则都触发的共同集合包含 306 题：

Timing	Readout	N	停机答案准确率	Mean stop tokens	Continuation match
simple	simple	306	81.0%	886	84.3%
simple	certainindex	306	81.7%	886	84.3%
certainindex	simple	306	90.2%	1,480	95.4%
certainindex	certainindex	306	90.8%	1,480	95.8%

- **Readout** 主效应：+0.65pp。固定 stop 时刻后，换措辞几乎不改变正确率。
- **Timing** 主效应：+9.15pp。把 stop 推后约 594 tokens，准确率明显上升。
- 解释份额：93.3%。Headline 的非共同集合分析中，timing 份额为 96.1%。

直观例子。同一道题，simple 在约 886 tokens 触发，certainindex 在约 1,480 tokens 触发。若仍在 886 tokens，只把问题换成 certainindex 措辞，准确率只升 约 0.7pp；真正的大变化来自允许主推理继续约 600 tokens。

4.3 被 certainindex 拒绝的 simple stop

simple-only 集合实际包含 110 题，而不是简单相减得到的 105：

- 35 题属于 wrong-to-correct recovery，拒绝早停直接有益；
- 5 题属于 correct-to-wrong overthinking，拒绝早停有害；
- 35 题已经 terminal 且正确，拒绝只增加延迟；
- 其余 35 题最终仍错，或从一个错误答案换到另一个错误答案。

因此 `certainindex` 的拒绝不是全部有益，但 `recovery` 明显多于 `overthinking`。这支持 `patience/min_tokens`，同时也说明必须通过 `Pareto sweep` 控制等待成本。

4.4 为什么选择 `simple@32`

Probe	空答案率	平均输出 tokens	撞输出上限	结论
<code>simple@10</code>	6.34%	9.20	79.55%	长答案常被截断
<code>certainindex@10</code>	5.76%	9.74	93.27%	更保守但成本高
<code>simple@32 + stop</code>	0.60%	6.43	0.94%	完整且更便宜
<code>certainindex@32 + stop</code>	0.42%	6.28	0.80%	同样完整

“32 token 上限”不等于每次使用 32 tokens。加入 `\]` 闭合 `stop` 后，短答案通常约 6 tokens 就结束，只有长表达式使用额外预算。因此 `simple@32` 同时修复空串/截断，并降低实际 `probe` 成本。

5 Step 2 + Step 4: Pareto Sweep 与规则型 Governor++

5.1 首轮 Train / validation / test / Qwen 流程

数据段	N	用途	是否允许调参
Train	300	评估完整规则网格	允许
Validation	101	验证约束并选择 conservative/ balanced/aggressive	允许选择
DeepSeek test	99	冻结配置后一次性评估有效性和稳定性	不允许
Qwen planned holdout	500	跨模型迁移检查	不允许

101/99 不是数据丢失。每个 MATH level 内分别计算 60/20/20，并对 train 与 validation 的人数独立四舍五入；五个 level 的舍入误差相加后得到 `validation=101`，剩余 `test=99`。总数仍为 500，各 level 均保持近似比例。

这里的术语必须严格区分：

- `validation` 用于“选哪个规则”；
- `DeepSeek test` 才是同模型 held-out；
- `Qwen` 是更严格的跨模型 transfer holdout。

不能把 `validation accuracy` 当成最终泛化结果。首轮 `Qwen` 后来因 `simple@10` 与 `DeepSeek simple@32` 不匹配而作废；第二轮的 `matched@32` 协议见后文。

5.2 搜索空间与选择标准

- 输入流：Step 1 选出的 `simple@32`，并计入真实 `probe` 输出 token；
- 规则轴：fixed / MATH-level / online-instability floor, patience, history stability, certain 与 schema validity；
- Conservative: train 和 validation 的准确率下降都不超过 1pp；

- **Balanced**: train 和 validation 的准确率下降都不超过 3pp;
- 满足约束后, 在 train+validation pooled development 集上选总 token 最少者;
- test 与 Qwen 只评估冻结候选。




图 3: 同一批规则在 train 与 validation 上的 accuracy-compute sweep。两幅图使用相同坐标轴和相同颜色; 候选必须在两边同时满足准确率约束, 不能只看其中一幅。

图 3 左右呼应地展示了选择流程: train 用于初筛, validation 用于检查候选是否 保持同样的 accuracy-compute 关系。某个点只有在 train 漂亮、validation 也稳定时, 才有资格进入下一轮; validation 上偶然出现的高点不能单独成为最终结论。

5.3 规则名称怎么读

报告中的缩写描述的是完整 stop 条件, 而不是模型名称:

缩写	完整含义	例子
p3 / p6 / p8	patience: 最近连续 3 / 6 / 8 个有效 probe 必须给出数学等价的同一答案	p8 比 p3 更保守, 需要更长稳定期
fixed1024	固定 token floor: 任何题在 1,024 tokens 之前都不允许停	不区分题目难度
level768/2048	MATH level 自适应 floor: level 1-3 最早 768 tokens; level 4-5 最早 2,048 tokens	level768/1536 的难题 floor 是 1,536
schema	有效性过滤: 空答案无效; MATH500 是非选择题, 因此单字母 A-D 也无效	防止 "B", "B", "B" 被当成数学共识
nonempty	只过滤空答案, 不过滤单字母格式伪影	比 schema 更宽松
certain / cert1	patience 窗口内的 probe 都不能包含 wait/but/hmm/no 等犹豫词	cert0 表示不要求这一条件

Conservative、**Balanced**、**Aggressive** 是三个风险/准确率预算档位：Conservative 要求 train 和 validation 的准确率损失都不超过 1pp，Balanced 不超过 3pp，Aggressive 只追求最大 token saving。因此同名档位在不同 sweep 中可以对应 完全不同的具体规则。

5.4 Validation 选出的新候选

工作点	规则	Val accuracy	Val tokens	Coverage	False-stop
Conservative	p3 + level floor 768/2048 + schema	81.2%	1,783	70.3%	16.9%
Balanced	p3 + level floor 768/1536 + schema	78.2%	1,616	77.2%	20.5%
Aggressive	p3 + no floor + nonempty	65.3%	1,143	93.1%	35.1%

5.5 首轮 held-out：为什么 p3 候选被淘汰

规则	DeepSeek test Δ acc	DS saving	判定
Stage-7 Conservative v0 (旧)	+2.0pp [-2.0,+6.1]	14.0%	保留基线
Stage-7 Balanced v0 (旧)	+1.0pp [-3.0,+5.1]	20.6%	同模型通过
Stage-10 Conservative candidate (新)	-4.0pp [-9.1,+1.0]	22.9%	淘汰
Stage-10 Balanced candidate (新)	-5.1pp [-11.1,+1.0]	31.0%	淘汰

首轮 Qwen 使用的是 simple@10，而 DeepSeek 已换成 simple@32，因此旧表里的 Qwen token 与准确率比较不再作为正式证据，本报告已将它删除。仅看可比的 DeepSeek test，新 p3 规则虽然在 validation 上省得更多，却掉了 4-5pp，已经足够判定失败。

这里“旧 Conservative”和“新 Conservative”不是同一个配置：

- 旧 **Conservative v0** 是 Stage 7 已经冻结的基线：p8 + fixed1024 + certain + schema。它要求连续 8 个有效且确定的相同答案，所有题都在 1,024 tokens 后才允许停。它没有参加本轮 train/validation 重新选型，只是作为预先冻结的 baseline 直接拿到 test 上比较。
- 新 **Conservative candidate** 是本轮 Stage 10 扩展网格在 train+validation 选出的候选：p3 + level768/2048 + schema。它只要求连续 3 次相同，但 level 4-5 必须等到 2,048 tokens；它不要求 certain。

两者都叫 Conservative，只因为它们分别是各自 sweep 中“准确率损失不超过 1pp”档位的最省 token 规则。旧版依赖更长的通用稳定期；新版尝试用难度自适应 floor 换取更多 coverage。Held-out 结果说明这次替换没有泛化成功。

5.6 第二轮：扩宽 candidate funnel

首轮每档只冻结一个候选，容易把 validation 的偶然赢家当成答案。第二轮保持同一 风险预算，但让更多、且来自 consecutive/history 两个家族的规则继续向下游流动：

阶段	Conservative	Balanced	Exploratory	合计	用途
Train	40	40	40	120	完整网格初筛
Validation	15	15	15	45	保持 train 风险上界
Validation-2	6	7	8	21	former test; 允许 2pp 离散缓冲
Matched Qwen@32	6	7	8	21	21 个 finalist 全测；跨模型外部门控

原来的 99 题 test 在这里被明确改名为 **validation-2**，因为我们查看它并继续筛选了多个规则；它已不再是 untouched test。Qwen 也同时评估了 21 个 finalist，所以它是外部 development gate，而不是选出赢家后的无偏最终估计。最终数字仍需新 seed 确认，但这比每层只留下一个候选更不容易漏掉稳定工作点。




图 4: 左图显示扩宽漏斗每轮保留的候选数；右图在 matched Qwen simple@32 上比较 token saving、false-stop 与准确率损失。黑星是推荐规则，蓝菱形是旧 v0。

5.7 Matched Qwen@32 与最终取舍

下表中每个模型的三元组依次是 Δ accuracy / token saving / false-stop:

规则	DeepSeek validation-2	Matched Qwen@32	判定
Stage-7	+2.0pp / 14.0% / 10.0%	-1.2pp / 29.7% / 15.5%	更保守 fallback
Conservative v0			
p5 + level768/2048 + certain + schema	0.0pp / 17.7% / 15.8%	-1.0pp / 32.2% / 18.4%	推荐
mv3/share1 + level768/2048 + certain + schema	-1.0pp / 18.4% / 18.3%	-0.8pp / 32.5% / 18.4%	更省, 但 DS false-stop 更高
mv3/share1 + level512/1536 + schema	-2.0pp / 26.2% / 19.7%	-2.6pp / 41.5% / 21.0%	Balanced
p4 + level512/1024 + certain + schema	-2.0pp / 35.1% / 21.3%	-6.8pp / 52.4% / 26.9%	跨模型淘汰

推荐规则的配对 bootstrap 区间为: DeepSeek $\Delta\text{acc} = 0.0\text{pp}$ $[-4.0, +4.0]$; Qwen $\Delta\text{acc} = -1.0\text{pp}$ $[-3.8, +1.6]$ 。没有显著掉点, 但区间并不等于“证明零风险”。

内部配置名 `hist_w5_mv5_s1.0_level768-2048_swany_span0_cert1_validschema` 可以简单读成 p5 规则: 最近窗口 `w5` 中必须有 `mv5` 个有效答案, `s1.0` 表示 五个答案 100% 数学等价; `swany/span0` 表示不再叠加全历史换答案次数或额外稳定 跨度限制。因为窗口正好 5 且要求 5 个都有效, 它在逻辑上就是“连续五个有效、确定、格式合法的 probe 全部一致”。

5.8 当前 Rule-based Governor++ 推荐

均衡的 accuracy-first 候选:

```
valid_schema == True
AND token_position >= 768    if MATH level <= 3
AND token_position >= 2048   if MATH level >= 4
AND last 5 probes are valid and mathematically equivalent
AND probe is certain
```

它把 p3 的过早风险改成五次完全一致, 并只让 level 1-3 在 768 tokens 后早停; level 4-5 必须等到 2,048。相较旧 v0, 它在两个模型上多省约 2.5-3.7pp total tokens, 代价是 false-stop 高约 2.9-5.8pp。若部署目标把 false-stop 放在 token saving 之前, 仍可选 Stage-7 v0; 若按本项目当前“高准确率硬门槛后平衡成本与 false-stop”的标准, 则推荐新 p5 level 规则。

6 Step 3: 晚共识为什么看起来不可靠?

6.1 实验设计: 同题 K-rollout 锁死题目难度

旧曲线把不同题混在一起: 简单题通常早收敛且答对, 难题通常晚收敛且答错。要区分“题难”和“轨迹晚”, 实验对同一道题重复 $K=8$ 次, 使题目难度在组内完全相同。

项目	实际设置
问题数	80: MATH 50 + AIME24 30

项目	实际设置
Rollouts	每题 K=8, 共 640 条
Token budget	16,384, 高于 plan 的 12k 初始值
Probe rows	30,524
MATH finish / accuracy	96.25% / 85.0%
AIME finish / accuracy	66.25% / 52.5%; cap 仍达 33.75%
主 consensus 定义	last-5 至少 3 个非空; 数学等价 dominant share ≥ 0.8

6.2 Within-between 分解

Consensus Time (CT) (共识形成时间) 定义为: 沿一条 rollout 每隔固定 token 位置打 probe, 在最近 5 个 probe 中至少有 3 个非空答案时, 如果数学等价的多数答案 占这些非空答案的比例达到 0.8, 就把第一次满足该条件的 **token** 位置记为 CT。例如第一次在 1,536 tokens 处满足 last-5 dominant share ≥ 0.8 , 则 $CT = 1536$ 。CT 不是总生成长度, 也不是连续一致次数; 它表示“局部共识第一次形成 得足够强”的时间。

主模型为:

$$\text{correct} \sim \text{ct_within} + \text{ct_problemmean} + (1 \mid \text{problem}).$$

- **ct_within**: 同一道题的某次 rollout 比该题自己的典型 CT 早或晚;
- **ct_problemmean**: 这道题整体比其他题早或晚。

CT 使用 $\log_2(\text{tokens})$, 因此一个单位表示 CT 翻倍。

例子。同一道题的一条 rollout 在 1,000 tokens 达成共识, 另一条在 2,000 tokens, 这是一次 within 翻倍; 题目 A 的典型 CT 为 1,000, 题目 B 为 2,000, 则是一次 between 翻倍。前者问轨迹级规律, 后者主要反映题目难度。




图 5: 左图混合所有题目, 呈现明显下降; 右图按题内相对 CT 比较后, 单调下降消失, 中段最可靠。

6.3 主模型结果

Outcome	同题内 CT 翻倍	题间平均 CT 翻倍	直观结论
Final correctness	OR 1.127, $p=.282$, +1.9pp	OR 0.521, $p=.007$, -11.7pp	晚不是同题内的伤害因素
Consensus correctness	OR 1.765, $p=.001$, +10.5pp	OR 0.447, $p=.001$, -15.2pp	同题内晚共识更可能正确
Terminality	OR 1.810, $p<.001$, +11.8pp	OR 0.721, $p=.094$, -7.0pp	同题内晚共识更稳定

OR 是 odds ratio，不是准确率直接相乘。报告同时给平均概率变化：

- 同题内 CT 翻倍，最终正确率平均 +1.9pp，但 $p=.282$ ；
- 因此不能宣称晚共识提升最终准确率；
- 可以可靠地说：没有证据显示同题内晚共识使最终正确率下降。




图 6: CT 翻倍的 odds ratio。虚线 1 表示没有变化；final correctness 的 within 置信区间跨 1，而 between 显著小于 1。

6.4 精准根因

1. 难题混杂。
题目 pass rate 与平均 CT 的 Spearman 相关为 -0.602, $p=3.48e-9$ 。收敛晚首先是在标记“这道题难”。
2. 过早的暂态共识。
127 条 rollout 从错误共识恢复为最终正确，只有 10 条从正确共识走向最终错误。Recovery 是 overthinking 的 12.7 倍。

3. **Token cap** 放大尾部失败。
自然结束轨迹最终准确率 82.9%，cap 轨迹只有 15.9%；绝对 CT >4k 的组中，cap rate 达 32.4%。
4. 关系不是单调的。
二次项显著：中段最可靠；极早的共识常是暂态，极晚的轨迹常位于能力边界，并伴随更高 cap 风险。

修正后的结论是：

不能把“absolute CT 越晚越不可信”作为独立停止规则。Governor 应用 min_tokens/patience 阻止过早暂态共识，同时把 CT 当作题目难度和 cap 风险信号，联合 validity、稳定性和在线难度代理判断。

7 Step 5: 为什么现在不训练 calibrator

plan.md 第 8.3.0 节要求三项 gate 同时满足：

Gate	要求	当前证据	结论
缺口存在	规则撞到 Pareto 天花板，并有理由相信更复杂组合能突破	扩宽漏斗已找到简单 p5 level 工作点，没有暴露必须学习的残余缺口	不满足
非线性交互重要	多信号/难度自适应候选稳定优于简单规则	history 的复杂约束没有稳定压过五次完全一致	不满足
标签可用	safe-stop = correct AND terminal AND valid	correctness/terminality 已有；validity 仍只有有限 audit	基本满足但需扩充

前两项都不满足。此时训练 logistic/GBM 更可能把 development 选择噪声编码进模型，而不是解决一个已被证明存在的规则缺口。

Decision: No-go. 保留轻量 calibrator 设计，但当前不训练、不宣传。只有新 seed 上出现可复现、且扩大规则网格仍无法修复的缺口，才重新打开 Step 5。

8 统一后的 Governor++ 设计原则

控制信号	证据来源	当前规则映射
Validity	Stage 6: single-letter 0% valid; 空串/格式伪影	schema filter; 非空; 非 MC 禁 A-D 单字母
最早停止时间	Step 1: 93%-96% 的增益来自 timing	min_tokens=1024 起步
持续稳定	127 recovery vs 10 overthinking	patience=8; 要求 recent answers 稳定
难度	Step 3: between -11.7pp per CT doubling	在线 entropy/switches 作为风险提示，不用离线 pass rate
Consensus time	within 最终正确率无负效应	不作单独“越晚越拒绝”的阈值

控制信号	证据来源	当前规则映射
Token cap	cap 轨迹准确率 15.9%	高 cap 风险时降低 stop 信任，并显式报告截断

这些证据支持一种不对称的控制策略：

- 对极早的共识保持耐心，因为 recovery 远多于 overthinking；
- 对中段稳定、有效的共识允许停止；
- 对极晚且接近 cap 的轨迹提高风险提示，但不能简单认为“晚所以错”；
- 任何自适应难度规则都必须在冻结 test 和跨模型 holdout 上重新证明自己。

9 完成度、限制与下一步

9.1 已经闭环的科学问题

- Probe 措辞是否提供独立 readout 增益？
基本没有，主要是 **timing**。
- simple@32 是否值得作为新底座？
值得：空率更低且实际 **probe token** 更少。
- 更复杂规则能否直接突破 Pareto？
扩宽漏斗后，简单 **p5 level** 规则得到一个新的保守工作点；复杂 **history** 约束没有显示额外优势。
- 晚共识是否在同题内真的更差？
不是；主要是题间难度和 **cap**。
- 是否现在训练 calibrator？
否；**gate** 不满足。

9.2 仍需完成的工程与稳健性工作

优先级	任务	目的
P0	最终推荐规则多 seed	给 1-2pp 差异估计真实方差
P0	新 untouched test / seed	因 validation-2 与 Qwen 已参与 21 个候选选择，需要无偏终验
P1	Rule Governor++ controller 包装	把推荐 p5 level 规则变成可运行、可记录、可回放的组件
P1	扩大 validity audit	补足 safe-stop 标签，尤其 @32 probe
P2	新模型/数据集	GSM8K、GPQA-Diamond、第 3 个模型

9.3 解释边界

关于 **591** 和 **621** 两个数字。这里的 **share** 是最近 5 个 probe 的非空答案中，数学等价的多数答案所占比例。远端 agent 在实验刚结束时做了一张快速诊断表，实际把 阈值设成了较宽松的 0.6，却在文字里误写成 0.8。正式分析从原始 probe 重新计算后，使用 plan 规定的主阈值 0.8：

判定阈值	形成过共识	从未形成	在报告中的用途
dominant share ≥ 0.8	591 / 640	49 / 640	正式主分析
dominant share ≥ 0.6	621 / 640	19 / 640	宽松阈值敏感性分析

因此，621 不是另一批数据，也不是丢了 30 条 rollout。它只是门槛更宽松后，多了 30 条“share 达到 0.6、但没有达到 0.8”的轨迹。我们又用 0.6 阈值完整重跑了主要模型，within/between 的方向和根因结论没有改变，说明结论不是由 0.8 这个单一阈值偶然造成的。正式报告其余结果仍统一采用 0.8。

其他限制：

1. K-rollout 的 within effect 是强观测对照，不是操纵 consensus time 的随机因果实验。
2. AIME 即使在 16,384 token budget 下仍有 33.75% cap，必须与 MATH 和 natural-finish sensitivity 一起解读。
3. Matched Qwen simple@32 已完成，但同时比较了 21 个 finalist；它是外部 development gate，不是选型后的 untouched estimate。
4. 关键实验仍为单 seed；最终部署前必须报告新 seed 方差，并保留一次未参与选择的最终测试。

10 产出物与复现索引

模块	主要产出
Step 1	results/probe_paired_2x2/report.md、analysis_2x2.json、reprobe_paired.csv
Step 2/4 首轮	results/stage10_rule_sweep/report.md、selected_*.csv、pareto_validation.png
Step 2/4 扩宽漏斗	results/stage10_rule_funnel_v2/report.md、round1_* 至 round4_*
Matched Qwen@32	results/stage11_cross_model/qwen3_8b_math500_simple32/reprobe_paired.csv；远端提交 3a844f3
Step 3	results/stage9_krollout_analysis/report.md、model_results.csv、root_cause_summary.json
分析脚本	probe_compare/analyze_2x2.py、probe_compare/analyze_krollout.py、replay/sweep_stop_rules_v2.py、replay/sweep_stop_rules_funnel.py
规划	plan.md 第 6.6、7.5、8.2a、8.3.0、19 节

报告数字均来自上述冻结产出。HANDOVER.md 仅用于交接，不作为正式结果来源，也未纳入提交。