

Governor v2 相关工作基线实验报告

1. 执行结论

全量数据已就绪 (8208 行，3 方法 × 2736 轨迹/方法)。

完整主结果显示：准确率保留最好的是 DEER / Qwen/Qwen3-8B (宏平均 $\Delta acc = +0.78pp$)；公平 token 节省最高的是 CertalIndex mid / Qwen/Qwen3-8B (90.10%)。存在 $\leq 3pp$ 准确率损失的相关工作点。这些结论只针对冻结轨迹复现，不反推原论文端到端结果。

2. 实验范围与复现标签

- 模型: DeepSeek-R1-Distill-Qwen-7B (rev 916b56a), Qwen3-8B (rev b968826)
- 基准: MATH500 (400/env), AMC23 (32/env), AIME24 (24/env)
- 种子: 42, 43, 44
- 环境数: 18 (2 模型 × 3 基准 × 3 种子), 轨迹总数: 2736
- 阶段: development (train+dev), 无测试数据
- 协议版本: governor-v2-preregistered-2026-07-27.10
- 拆分种子: 20260726

3. 方法/协议表

方法	模块	来源 (pin)	复现类别
CertalIndex faithful mid TJE	certainindex_mid.py tje.py	dynasor/core/cot.py @ dbe76ad https://aclanthology.org/2026.findings-eacl.263/ (Fig.2+\$2.2)	忠实 prompt+ 停止规则; 冻结轨迹时间 冻结轨迹 TJE 复现
DEER	deer.py	https://github.com/iie-ycx/DEER @ c9dd19f	冻结轨迹 DEER 复现

4. 覆盖率

- 方法数: 3
- 环境数: 54
- 每方法行数: { ‘certainindex_mid_frozen’ : 2736, ‘deer_frozen’ : 2736, ‘tje_frozen’ : 2736 }
- 测试行数: 0

5. Dev 模型 × 基准表

模型	基准	方法	准确率	全量准确率	准确率差 (pp)	95%CI(准 确率差)	全量 token 节省	95%CI(token 节省)	主 token 节 省	停止率	探针开销 (token)
Qwen/Qwen3-aime24 8B		CertIndex mid	0.00%	83.33%	-83.33	[-100.00, -66.67]	90.49%	[81.49, 96.70]	91.30%	100.00%	106.8
Qwen/Qwen3-amc23 8B		CertIndex mid	0.00%	83.33%	-83.33	[-95.83, -66.67]	89.94%	[81.97, 95.68]	90.65%	100.00%	66.8
Qwen/Qwen3-math500 8B		CertIndex mid	46.00%	89.67%	-43.67	[-50.00, -37.00]	89.88%	[87.82, 91.52]	91.06%	99.33%	62.0
deepseek-ai/DeepSeek- R1-Distill- Qwen-7B	aime24	CertIndex mid	11.11%	61.11%	-50.00	[-77.78, -22.22]	64.01%	[43.72, 82.88]	66.80%	100.00%	357.7
deepseek-ai/DeepSeek- R1-Distill- Qwen-7B	amc23	CertIndex mid	12.50%	87.50%	-75.00	[-91.67, -54.17]	83.87%	[72.36, 91.89]	85.01%	100.00%	85.5
deepseek-ai/DeepSeek- R1-Distill- Qwen-7B	math500	CertIndex mid	48.00%	90.67%	-42.67	[-48.67, -36.67]	82.16%	[78.42, 85.28]	84.01%	96.00%	69.2
Qwen/Qwen3-aime24 8B		DEER	83.33%	83.33%	0.00	[0.00, 0.00]	5.10%	[-0.52, 14.46]	7.85%	22.22%	365.4
Qwen/Qwen3-amc23 8B		DEER	83.33%	83.33%	0.00	[0.00, 0.00]	10.37%	[1.91, 21.89]	14.38%	29.17%	376.1
Qwen/Qwen3-math500 8B		DEER	92.00%	89.67%	2.33	[-0.33, 5.00]	33.42%	[26.18, 41.03]	41.87%	72.67%	445.3
deepseek-ai/DeepSeek- R1-Distill- Qwen-7B	aime24	DEER	61.11%	61.11%	0.00	[0.00, 0.00]	4.18%	[0.54, 11.96]	6.19%	38.89%	257.1
deepseek-ai/DeepSeek- R1-Distill- Qwen-7B	amc23	DEER	83.33%	87.50%	-4.17	[-16.67, 0.00]	16.39%	[5.71, 31.78]	21.41%	50.00%	378.3
deepseek-ai/DeepSeek- R1-Distill- Qwen-7B	math500	DEER	80.33%	90.67%	-10.33	[-14.33, -6.33]	39.92%	[31.85, 47.67]	49.43%	79.33%	356.0
Qwen/Qwen3-aime24 8B		TJE	83.33%	83.33%	0.00	[0.00, 0.00]	-1.83%	[-2.23, -1.47]	0.00%	0.00%	242.8
Qwen/Qwen3-amc23 8B		TJE	83.33%	83.33%	0.00	[-16.67, 16.67]	4.36%	[-1.97, 14.89]	7.45%	20.83%	289.5
Qwen/Qwen3-math500 8B		TJE	88.33%	89.67%	-1.33	[-4.33, 1.33]	3.57%	[0.23, 7.20]	10.02%	46.67%	339.7

模型	基准	方法	准确率	全量准确率	准确率差 (pp)	95%CI(准确率差)	全量 token 节省	95%CI(token 节省)	主 token 节省	停止率	探针开销 (token)
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	aime24	TJE	33.33%	61.11%	-27.78	[-50.00, -5.56]	73.48%	[57.75, 84.65]	89.42%	100.00%	2042.7
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	amc23	TJE	66.67%	87.50%	-20.83	[-45.83, 4.17]	65.05%	[43.69, 77.40]	79.11%	100.00%	1057.8
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	math500	TJE	82.00%	90.67%	-8.67	[-12.67, -5.00]	56.47%	[50.21, 61.82]	66.82%	80.33%	387.3

6. Dev 宏观视图（不使 MATH500 按样本数主导）

方法	模型	基准数	准确率	准确率差 (pp)	全量 token 节省	主 token 节省	停止率
CertaIndex mid	Qwen/Qwen3-8B	3	15.33%	-70.11	90.10%	91.00%	99.78%
CertaIndex mid	deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	3	23.87%	-55.89	76.68%	78.60%	98.67%
DEER	Qwen/Qwen3-8B	3	86.22%	0.78	16.29%	21.37%	41.35%
DEER	deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	3	74.93%	-4.83	20.16%	25.68%	56.07%
TJE	Qwen/Qwen3-8B	3	85.00%	-0.44	2.03%	5.82%	22.50%
TJE	deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	3	60.67%	-19.09	65.00%	78.45%	93.44%

7. Accuracy-compute Pareto

模型	方法	宏平均准确率	相对 Full	公平 token 节省	非支配
Qwen/Qwen3-8B	Full generation	85.44%	+0.00pp	0.00%	否
Qwen/Qwen3-8B	CertaIndex mid	15.33%	-70.11pp	90.10%	是
Qwen/Qwen3-8B	DEER	86.22%	+0.78pp	16.29%	是
Qwen/Qwen3-8B	TJE	85.00%	-0.44pp	2.03%	否
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	Full generation	79.76%	+0.00pp	0.00%	是

模型	方法	宏平均准确率	相对 Full	公平 token 节省	非支配
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	CertIndex mid	23.87%	-55.89pp	76.68%	是
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	DEER	74.93%	-4.83pp	20.16%	是
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	TJE	60.67%	-19.09pp	65.00%	是

“非支配” 仅在同一模型的 Full + 三个相关工作主点内部计算；准确率越高、token 节省越高越好。

可用 **Governor** 探索点（非严格 **matched** 参考）

历史探索点	准确率	相对 Full	token 节省
Full	80.67%	+0.00pp	0.00%
Governor Conservative	80.73%	+0.06pp	-4.41%
Governor Balanced-MATH	80.67%	+0.00pp	0.88%
Dynasor on simple@32 (adapted)	69.73%	-10.94pp	35.78%
Naive agreement	64.40%	-16.27pp	48.91%

- 来源文件：benchmark/FalseConsensus/report/report_final_eval_multiseed_2026-07-26.md
- 来源 SHA-256：9823062064fa479cffe018c6013659d8affd34ba54f8b5c9f10ed18ba6513556

该表是历史三-seed MATH500 探索结果，模型/seed/任务构成与本报告的 18 个 development 环境不完全匹配；只用于定性定位，不能和上表作严格横向显著性比较。

8. Matched-accuracy / matched-token 解读

- **Qwen/Qwen3-8B** :
 - matched-accuracy (损失 ≤1pp) 最省的是 DEER：16.29%，Δacc=+0.78pp。
 - matched-accuracy (损失 ≤3pp) 最省的是 DEER：16.29%，Δacc=+0.78pp。
 - matched-accuracy (损失 ≤5pp) 最省的是 DEER：16.29%，Δacc=+0.78pp。
 - 最近的 matched-token 对是 DEER 与 TJE (节省差 14.26%)；准确率差为 +1.22pp。
- **deepseek-ai/DeepSeek-R1-Distill-Qwen-7B** :
 - matched-accuracy (损失 ≤1pp)：没有相关工作基线满足。
 - matched-accuracy (损失 ≤3pp)：没有相关工作基线满足。
 - matched-accuracy (损失 ≤5pp) 最省的是 DEER：20.16%，Δacc=-4.83pp。
 - 最近的 matched-token 对是 CertIndex mid 与 TJE (节省差 11.68%)；准确率差为 -36.80pp。
- 每个方法只有一个预注册主 operating point；因此不存在连续阈值曲线时，不能把“最近点”解释为严格的等 token 因果比较。

9. 公平计费说明

两种成本视图：

1. 论文式 `main_tokens_through_stop` - 冻结推理长度到停止（或全长如无停止）
2. 公平全量 `all_generated_tokens` = 主停止长度 + 所有探针/试错/读出输出 `token`

探针/试错/读出 **prompt token**（重发前缀）单独报告，不计入全量生成 `token`。

配对分层 **bootstrap**: 10000 样本, 种子 20260727 - 先重采样种子，再在种子内重采样配对问题行。仅在 `dev-pooled + train+dev` 视图运行（非逐环境）。

10. 失败、截断与解析诊断

模型	方法	行数	辅助调用	无效辅助响应	capped/right-censored	恢复截断	过度思考避免	辅助 wall time(s)
Qwen/Qwen3-8B	CertaIndex mid	1368	11157	1164 (10.433%)	0.000%	99.342%	99.342%	3060.8
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	CertaIndex mid	1368	16036	865 (5.394%)	0.000%	97.661%	97.661%	4060.1
Qwen/Qwen3-8B	DEER	1368	8072	277 (3.432%)	4.825%	70.175%	70.175%	16093.5
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	DEER	1368	5945	258 (4.340%)	3.874%	75.512%	75.512%	13301.5
Qwen/Qwen3-8B	TJE	1368	32854	49 (0.149%)	4.386%	43.567%	43.567%	24448.6
deepseek-ai/DeepSeek-R1-Distill-Qwen-7B	TJE	1368	5818	58 (0.997%)	0.073%	84.137%	84.137%	20685.0

`invalid_aux_responses` 是已完整记录的方法级失败（交付空答案并计错），不是丢行；8192-token TJE 与 4096-token DEER readout 触顶作为 `capped/right-censored` 诊断保留。请求错误、`context overflow`、缺行仍是硬失败。

11. 局限性

- TJE/DEER 为冻结轨迹复现，非端到端忠实运行（冻结轨迹 TJE/DEER 复现标签）
- TJE 的 `structured_outputs.choice` 约束改变了标签分布（vs 无约束），影响触发率
- AMC/AIME 样本量小（32/24），置信区间较宽
- 模型可能声称高置信但在固定读出 `cap` 内无法完成 `boxed` 答案；该结果按方法失败计错，不补用未来完整答案
- 历史 **Governor** 探索点与当前 18 环境网格不完全匹配，只可定性参照

12. 精确修订/哈希

- deepseek: model=deepseek-ai/DeepSeek-R1-Distill-Qwen-7B rev=916b56a44061fd5cd7d6a8fb632557ed4f724f60 endpoint=http://127.0.0.1:18000/v1
- qwen3: model=Qwen/Qwen3-8B rev=b968826d9c46dd6066d109eabc6255188de91218 endpoint=http://127.0.0.1:18001/v1
- split manifest: benchmark/FalseConsensus/governor_v2/generated/split_manifest.json
- 每个 collector manifest 记录 source commit、prompt/config hash、输入 trajectory bank hash 与 split hash

13. 复现命令

验证冻结银行

```
python -m benchmark.FalseConsensus.related_work.preflight
```

全量收集（每模型）

```
bash benchmark/FalseConsensus/results/related_work/_runtime/run_full_model_pipeline.sh deepseek
```

```
bash benchmark/FalseConsensus/results/related_work/_runtime/run_full_model_pipeline.sh qwen3
```

后处理 (*replay + aggregate + report*)

```
python -m benchmark.FalseConsensus.related_work.postprocess
```

PDF 渲染

```
bash benchmark/FalseConsensus/results/related_work/_runtime/render_pdf.sh
```

14. Artifact inventory

- 原始逐题结果：benchmark/FalseConsensus/results/related_work/full/<model>__<benchmark>__seed_<seed>/<method>/
- 54 个 replay：benchmark/FalseConsensus/results/related_work/full/_replay/
- 聚合 JSON：benchmark/FalseConsensus/results/related_work/aggregate/aggregate.json
- 环境/dev/train+dev/宏视图 CSV：benchmark/FalseConsensus/results/related_work/aggregate/*.csv
- Markdown 报告：benchmark/FalseConsensus/results/related_work/aggregate/report.md
- PDF 报告：benchmark/FalseConsensus/results/related_work/aggregate/report.pdf
- 运行/验证日志：benchmark/FalseConsensus/results/related_work/full/_runtime/