

DEER-inspired Online Dev 结果

Seed 42 的 exploratory Dev 评估; 两个 BF16 模型、三个 benchmark, 所有推理、probe 与 verification branch 均在线执行。

结论

按 benchmark 等权宏平均, DEER-inspired 达到 **79.11% accuracy / 43.69% fair token saving**。相较在线 DEER, 准确率提高 +0.94%, token saving 提高 +15.37%。

方法	Macro accuracy	相对 Full	Fair token saving
DEER-inspired	79.11%	-0.36%	43.69%
Online DEER	78.17%	-1.31%	28.32%
差值	+0.94%	-	+15.37%

Fair token saving 计入 main generation、probe、verification 与 readout 的输出 token; 不包含输入 prompt/prefill 成本。

方法

- **DEER-inspired**: 1024 main tokens 后在 Wait 处 probe; 前 10 次 dense, 此后保持至少 512-token 间隔。置信度 >0.995 直接提交; >0.97 进入最多 64-token 的 retained verification branch, Stage-2 >0.99 且答案一致时提交。
- **Online DEER**: 从首个 Wait 起最多 probe 10 次; 置信度 >0.95 后 greedy readout。两种方法共享 online engine、prompt、采样与 seed policy。

分模型结果

模型	方法	Macro accuracy	相对 Full	Fair saving
DeepSeek-7B	DEER-inspired	72.67%	-3.50%	41.78%
DeepSeek-7B	Online DEER	78.78%	+2.61%	36.89%
Qwen3-8B	DEER-inspired	85.56%	+2.78%	45.59%
Qwen3-8B	Online DEER	77.56%	-5.22%	19.74%

Qwen3 上 DEER-inspired 同时提高 accuracy 与 saving; DeepSeek 上获得较小的 saving 增益, 但 accuracy 下降, 说明当前阈值仍存在模型依赖。

不确定性与配对结果

- Benchmark-stratified paired bootstrap (10,000 次): accuracy 差值 +0.97%, 95% CI [-10.50%, +12.56%]; 尚不能确认 accuracy 优势。
- Token-saving 差值 +15.32%, 95% CI [+7.33%, +22.93%]; 区间稳定为正。
- 逐题 pooled 配对: 相对 Online DEER, accuracy +6.14%, 平均少生成 685 tokens/题。
- 相对 existing full 的近似 counterfactual: accuracy +0.88%, 平均少生成 2536 tokens/题; 因在线多请求改变采样路径, 此项不是严格配对。
- Pooled 汇总受 MATH500 数量主导: DEER-inspired 为 89.47% / 38.09%, Online DEER 为 83.33% / 39.81%; 因此主文优先使用 benchmark 等权宏平均。

行为与完整性

- 审计状态 complete: 456/456 条结果齐全, 零 infrastructure error, token accounting 可重算。
- 126/228 题 fast commit; 35 次 verification branch 中 30 次提交; 2 题 capped。
- 共观察 3117 个 Wait; dense/sparse probes 为 742/283, 512-gap 跳过 1327 次。

限制

- 仅一个 seed; AMC23 (8 题) 与 AIME24 (6 题) 样本很小, accuracy CI 较宽。
- 本轮未读取 Test/confirmation, 也未回溯修改 Governor Pareto sweep。
- 结论可支持“显著改善 Online DEER 的 token trade-off”, 但跨模型稳定性仍需 Test 与更多 seed 验证。

详细的逐环境指标、逐题记录与 bootstrap 数据分别见 environment_metrics.csv、per_problem.csv 和 bootstrap.json。