

Governor Finding-Experiment 支撑矩阵

Claim-to-Evidence Audit with Experimental Appendix

2026-07-30

目录

1. 可靠性标准	2
2. 五项主 finding 总览	2
3. F1: False consensus	3
4. F2: 预注册搜索与 “no safe-and-saving rule”	4
5. F3: Accuracy tax 与 probe tax	5
6. F4: Related-work baselines 与 signal 对比	5
7. F5: Boundary confidence、fast path 与 verification branch	6
8. 跨 finding 的共同依赖	7
9. 当前最值得补的实验	7
10. 建议立即修订的论文措辞	8
11. 维护规则	8
Appendix: 具体实验数据与图表	9
A1. Governor v2 多元数据范围与完整性	9
A2. Agreement calibration、false consensus 与 window sensitivity	10
A3. Probe-1、first-consensus recovery 与 consensus time	11
A4. False-consensus taxonomy 与当前人工审计状态	12
A5. 17,712-rule Development sweep 与 conservative gate	13
A6. Rule-family frontier 与 adaptive event probing	14
A7. Accuracy-tax 的方向强度	15

A8. Dev-Test cross-split confirmation 17
A9. Confirmation 覆盖与 unseen-model 边界 18
A10. Related-work baselines 与 Governor Pareto 位置 18
A11. Fast-path-only 配对消融与 trial/readout 冗余 21
A12. 完整 DEER-inspired online controller: 三 seed Dev 22
A13. 聚合敏感性与 verification-branch 消融 23
A14. 协议、置信度与 token accounting 23
A15. Evidence gaps、反证与待完成实验 24
A16. 修复后的 Llama-8B 多 seed scale sweep 25
A17. Human evaluation 双标回收与验收 27
A18. Consensus window 轨迹、related-work anchors 与边际代价 29

更新日期：2026-07-30

用途：把论文中的每个 finding/claim 拆成可核验陈述，记录直接实验、证据边界、可靠性和下一步。本文是研究台账，不替代论文正文。

引用约定：每个原子 claim 都在对应章节顶部映射到一个或多个附录证据项 A1–A18。点击 PDF 中的附录编号可跳转到具体数据表、图、聚合口径和源 artifact；A15 专门记录尚未完成、仅探索性或被现有消融削弱的证据，A16–A18 记录后续新增的 scale、human-evaluation 与 long-window signal 证据。

1. 可靠性标准

Table with 3 columns: 等级, 判定标准, 论文中允许的表述. Rows include 高, 中, and 低 reliability levels with their respective criteria and allowed expressions.

可靠性评估的是“当前数据能否支撑这句话”，不是 finding 是否有研究价值。精确、窄范围的 claim 可以是高可靠；更宏大的外推即使方向合理，也可能只有中或低可靠。

2. 五项主 finding 总览

Table with 4 columns: Finding, 当前可守住的核心结论, 总体可靠性, 最薄弱环节. Rows include F1 False consensus, F2 Searched-space negative result, and F3 Accuracy tax / probe tax.

Finding	当前可守住的核心结论	总体可靠性	最薄弱环节
F4 Related-work contrast	同一 frozen harness 中 CertalIndex 严重掉点; TJE 落在长-window consensus 轨迹附近, DEER 的 stop safety 明显高于单纯 agreement	中	DEER/TJE 是 frozen adaptations; 跨方法比较不能单独证明 signal 的因果作用
F5 Boundary confidence	Fast path 有 train/dev 配对正面证据; 完整 online controller 的 36 个 run directories、1,368 rows 已统一审计, dev 三 seed 宏平均接近中性且有较高 saving	中 (探索性)	verification branch 当前没有带来净纠错, 且没有 test / 新模型验证

总览证据索引: F1 -> A1、A2、A3、A4、A17、A18; F2 -> A5、A6、A8、A9、A16; F3 -> A7、A14、A18; F4 -> A10、A18; F5 -> A11、A12、A13。

3. F1: False consensus

逐 claim 附录索引: F1.1 -> A1, A2; F1.2 -> A1, A3, A18; F1.3 -> A3, A7, A18; F1.4 -> A3; F1.5 -> A2, A18; F1.6 -> A4, A17; F1.7 -> A4, A17; F1.8 -> A5, A7。

ID	原子 claim	直接实验与主要结果	可靠性	安全措施与缺口
F1.1	Whole-trajectory consensus 与 online 可见的 recent-window consensus 不同	Governor v2 的 18 environments: 全轨迹一致 coverage 11.5% pooled / 4.7% macro, 正确率 97.5% / 98.1%; last-5 unanimous coverage 78.7% / 84.4%, false consensus 9.7% / 16.0%。见 A1-A2	高 (tested bank)	可跨本次两模型、三 benchmark、三 seeds 报告; 不外推到未测模型或 probe prompt
F1.2	短窗口 naive consensus early stop 会显著损害准确率	18-environment strict replay: w=3/5/8 macro accuracy drop 为 -46.60/-29.99/-17.29 pp; 扩展到 w=30 后 stop accuracy 仍仅为 74.5% macro / 85.3% pooled	高 (配对反事实)	明确这是 simplified strict heuristic; 结论是短 consensus 高风险, 而非 persistence 完全无效
F1.3	Continued reasoning 经常恢复正确答案	w=5 first consensus: 1,137 recovery vs 39 overthinking (29.15:1); 六个 model × benchmark cells 均同向。1,411 个 first-consensus 与 final 不同样本中 1,139 个最终正确	高	Recovery 是跨当前环境的主要机制; Probe-1 的 86.0%/78.0% 仅作 early-readout control
F1.4	Consensus 出现得更晚不代表更可靠	绝对位置从 <512 的 90.5% 降至 ≥8K 的 39.1%; 但按完整轨迹相对位置分箱为 85.6%、93.7%、95.1%、91.7%、84.4%, 不单调	低-中 (描述性)	只能说 absolute-token correlation 受难度/长度混杂; 不得写成稳健或因果规律
F1.5	Window share 不是校准良好的 correctness confidence	18-environment w=3/5/8 macro CCE 为 0.201/0.203/0.200; strict window 扩展到 w=30 后 stop accuracy 在 pooled/macro 仍只有 85.3%/74.5%	高 (tested windows)	可说本次 windows/settings 下 miscalibrated; 同时承认更长 persistence 明显改善 trade-off
F1.6	False-consensus errors 可分成数值/表达式坍塌、符号错误、推导缺口、格式伪影等类型	Task A 两位标注者均完成 134/134; 精确一致 47.76%, kappa=0.286, 主要分歧为 D (reasoning gap) 与 A (numeric collapse)	中低	类别存在, 但比例尚不稳定; 70 个冲突需按更明确的“中间量 vs 最终候选答案”定义仲裁
F1.7	Probe 本身会制造部分 false consensus (例如格式伪影)	两位标注者分别给出 23/27 个 format-hallucination labels, 但整体 taxonomy 一致性低, 且尚未做因果性 probe-prompt 消融	低-中	可报告为人工审计观察; 不能据此给出稳定比例或断言由 probe prompt 因果制造
F1.8	False consensus 不只存在于 Stage 1 的 3072-token 截断设置	Governor v2 16K/32K caps 的六个 model × benchmark cells 均观察到 last-5 false consensus (4.0%-48.5%), 三 seeds/cell; 并有 17,712-rule 回放的同向证据	高 (tested bank)	已是直接跨设置复现; 仍限定于两模型、三 benchmark 与 simple@32 probes

4. F2: 预注册搜索与 “no safe-and-saving rule”

逐 claim 附录索引: F2.1 -> A14; F2.2 -> A5, A14; F2.3 -> A5; F2.4 -> A5; F2.5 -> A5, A8; F2.6 -> A5; F2.7 -> A5, A6, A14; F2.8 -> A6; F2.9 -> A8; F2.10 -> A8; F2.11 -> A9, A16; F2.12 -> A15。

ID	原子 claim	直接实验与主要结果	可靠性	安全措辞与缺口
F2.1	评估协议将 stopping rule 与 main reasoning trajectory 解耦	每题先生成并冻结一条 main trajectory, 再对固定 prefixes 离线 probing; 规则只改变 stop/readout, 不改变 main trajectory。配置、manifest、probe banks 和 sweep archives 均保留	高	这是协议事实; 应称 probe-independent frozen-trajectory evaluation, 不是 online deployment
F2.2	搜索覆盖统一的 7 个规则维度和 4 个 family	17,712 个规则覆盖 schedule、maturity、evidence、persistence、certainty、validity、history, 规则哈希与归档可复算	高 (枚举事实)	“覆盖该 schema”可靠; “覆盖所有合理 consensus 方法”不成立
F2.3	搜索规模为 637,632 个 rule-environment-split rows	$17,712 \times 18 \times 2 = 637,632$, 分析文件复算一致, 见 direction_of_effect.txt	高	纯覆盖/完整性 claim
F2.4	Dev 上 conservative gate 为空	两模型 $\times$ 三 benchmark $\times$ seeds 42/43/44; 没有规则同时满足 per-model drop ≤ 1.5 pp、per-benchmark drop ≤ 2.0 pp、PSF ≥ 0.8	高	论文最强 negative claim; 必须限定 in the preregistered searched space, on dev
F2.5	Dev 上最安全规则的 worst-case per-model drop 为 1.85 pp	最小值 1.852 pp; 但 bootstrap 95% CI 约 [0, 5.56], 同一规则 test 为 0.11 pp	中	可作为 dev point estimate; 不能把 1.85 pp 写成稳定、普适下界
F2.6	所有 17,712 个规则在 Development selection 上的 worst-case per-model drop 都为正	train+dev selection 为 17,712/17,712; development cells 中 67.72% 掉点、6.75% 提升、25.53% 不变	高 (Development 搜索空间)	不能再混入无效 Llama run 的四模型 Test 统计扩张该全称; held-out 支撑改由 A8 同两模型 cross-split 提供
F2.7	正净节省至少要付出 4.87 pp 的 per-model drop	在 dense simple@32、interval 64 等既定 probe 计费下, 获得至少三个 positive-saving rules 的最低 worst-case drop 为 4.87 pp, 且对 PSF 0.5-0.8 稳定	中	必须和 dense-probe accounting 绑定; 不是 probe 成本下降后的普适 frontier
F2.8	Adaptive event probing 在当前规则池中被 simple window share 支配	Dev family frontier: adaptive 最佳 positive-saving 点 worst-case drop 9.70 pp、mean saving 14.2%; window share 对应 4.87 pp	中高 (当前 grid)	可说 did not help in our sweep; 不能否定其他 adaptive trigger/controller
F2.9	Dev frontier 在同模型 held-out test 上稳定	17,712 个规则的同两模型 dev/test worst-case drop Pearson $r=0.962$; dev gate pass 0、test-alone pass 272、both 0; 见 A8 strategy points	高	这是比 exact floor 更可靠的确认结论
F2.10	Test 上直接选出的“赢家”不能泛化回 dev	272 个 test-alone gate passers 在 dev 的 per-model drop 为 4.98-5.65 pp, 0 个同时通过	高	直接支撑 held-out selection 的必要性
F2.11	Negative frontier 跨规模/架构延伸	Qwen-32B 有 114 trajectories、3 benches、seed 45 的 scale evidence; 修复后 Llama-8B 又完成 3 benches $\times$ seeds 42/43/44 的 1,710 条 development trajectories 与 17,712-rule replay	中	Llama 修复恢复了跨架构 development evidence, 但旧 seed-45 confirmation 仍无效; 不得把 dev sweep 当 held-out confirmation
F2.12	“任何 consensus-based early exit 都不可能安全且省 token”	当前没有直接实验能覆盖无限规则空间、其他 probe prompt 或其他 domain	低/不支持	必须改为 no rule in the searched space; 这是论文措辞的硬边界

完整性补充: seen-model confirmation 已审计 18/18 environments、684 trajectories、无缺行/运行错误, 截断率 3.2%。Held-out scale 的 Qwen-32B 完成预注册单-seed 范围; Llama 原计划 3 个 environments, 实际只有 2 个, 且输出退化, 因此不得并入有效 confirmation, 见 A9。

5. F3: Accuracy tax 与 probe tax

逐 claim 附录索引: F3.1 -> A14; F3.2 -> A14; F3.3 -> A7, A18; F3.4 -> A5, A7, A18; F3.5 -> A14, A15, A18; F3.6 -> A14, A15。

ID	原子 claim	直接实验与主要结果	可靠性	安全措辞与缺口
F3.1	总 output-token 成本可分成 main stopping cost 与 consumed probe cost	定义为 $T=s+p$; gross saving $(B-s)/B$, net saving $(B-s-p)/B$; 所有相关报告按字段可复算	高	这是计费定义; 当前不包含 prompt/prefill、wall time、KV-cache memory
F3.2	Accuracy drop 来自 stop position, 而不是 probe output token 数量	在 frozen trajectory 中, 给定 stop position 和 committed answer, 改变 p 不改变 correctness; 这是协议内的确定性性质	高 (frozen 协议内)	可称 stop-position accuracy tax; online probing 若改变主生成则需另测
F3.3	Consensus stopping 破坏 recovery 远多于挽救错误 full answer	Named rules ratio 为 14.59-35.17; strict unanimous 的 harm/rescue 随 window 从 $w=3$ 的 33.44 降至 $w=12$ 的 5.95、 $w=30$ 的 2.03	高 (多规则、多 window)	Ratio 衡量 harm/rescue, 不等于 stop accuracy; 长窗口 ratio 变好仍可能含大量 persistent-wrong false stops
F3.4	Dense probing 可把 gross saving 变成负 net saving	最安全 entropy family 停得晚, 仍支付大量 probes; dev 最安全点 net saving 约 -8% 至 -9%	高 (当前计费)	可解释当前负 savings; 不可据此说 stop 本身增加 main tokens
F3.5	Probe tax 随 probe 密度降低, 并可通过 sparse probe / shorter probe / KV reuse 缓解	从计费公式上必然随 consumed probe tokens 下降; 但尚无完整 $\text{interval} \times \text{probe-length} \times \text{KV-reuse}$ 实验量化最终 Pareto	中	“reducible by construction”可说; “可恢复正净节省”目前只是待验证 hypothesis
F3.6	Accuracy tax 对任何 probing scheme 都不可消除	当前依据是 dense grid 使多数 stop positions 可达, 且更稀疏 schedule 只会取其子集	中	宜写 within frozen trajectories and reachable positions in our grid; online controller 可改变轨迹, 不能直接外推

6. F4: Related-work baselines 与 signal 对比

共同证据为 related-work aggregate report: 两模型、三 benchmark、seeds 42/43/44 的 train+dev/frozen-trajectory reproduction; 主表为 dev benchmark-macro。

逐 claim 附录索引: F4.1 -> A10; F4.2 -> A10, A14, A18; F4.3 -> A10, A18; F4.4 -> A10, A15, A18; F4.5 -> A10, A14, A18; F4.6 -> A14, A15。

ID	原子 claim	直接实验与主要结果	可靠性	安全措辞与缺口
F4.1	CertalIndex 在本项目轨迹上以巨大准确率代价换取高 saving	Qwen: $\Delta\text{acc} -70.11$ pp、saving 90.10%; DeepSeek: -55.89 pp、76.68%。逐 benchmark Δacc 范围分别为 $[-83.33, -43.67]$ 和 $[-75.00, -42.67]$ pp	高 (本 harness)	三 benchmark、三 seeds 均同向; 仍是 frozen timeline, 不代表原论文端到端数字
F4.2	TJE 表现高度依赖模型和 benchmark	Qwen 宏平均 -0.44 pp / 2.03%, 逐 benchmark saving -1.84% 至 4.30% ; DeepSeek -19.09 pp / 65.00%, 逐 benchmark $\Delta\text{acc} -27.78$ 至 -8.67 pp	中高 (异质性事实)	TJE 使用 frozen adaptation, structured choice 改变标签分布; 不宜写“忠实复现原方法整体性能”
F4.3	DEER 比单纯 agreement stopping 具有更高 stop safety	Pooled DEER 为 28.8% saving / 89.6% stop accuracy; saving 接近的 strict $w=20$ 为 29.6% / 84.1%。Macro 下 strict $w=30$ 仍比 DEER 低 12.2 pp stop accuracy	中高 (matched harness)	可说 boundary confidence 更有希望; DEER 仍是 frozen adaptation, 不是 signal-only 因果消融
F4.4	“问题主要在短 consensus signal, 而不是 early exit 本身”	Short windows 严重失准; 长 persistence 可移动到 TJE-like 轨迹, 但 tested $w \leq 30$ 仍达不到 DEER stop safety	中	这比“所有 consensus 都无用”更准确; 跨方法仍同时改变 trigger、trial generation 与 readout
F4.5	Related-work points 与 Governor/consensus candidates 的 Pareto 相对位置可审计	同一 frozen trajectories、answer grader 与 all-generated output-token accounting; A18 同时报告 pooled 和 environment-macro	中	每张图必须显式写明计费与聚合口径; 不能混用 all-generated/fair、net dense-probe、macro 与 pooled

ID	原子 claim	直接实验与主要结果	可靠性	安全措辞与缺口
F4.6	Baseline 数字可视为原论文报告水平	本实验没有复现所有原始部署细节，也没有在原论文全套 benchmark/settings 上运行	低/不支持	只能称 reproduction/adaptation on our harness

7. F5: Boundary confidence、fast path 与 verification branch

Online 证据分两层：seed 42 有正式的 aggregate report 和 audit；统一 Appendix evidence audit 又逐目录检查了 seed 42/43/44 的 36 个 method × model × benchmark runs、1,368 method-problem rows。36/36 manifests 完整、protocol version 与 config hash 唯一且一致、无缺题。后两 seed 的采集目录仍保留 nonformal provenance 标签，但“缺统一审计”已不再是证据缺口。

逐 claim 附录索引：F5.1 -> A11；F5.2 -> A11；F5.3 -> A12；F5.4 -> A12, A13；F5.5 -> A13；F5.6 -> A13；F5.7 -> A13；F5.8 -> A15；F5.9 -> A10, A11, A12；F5.10 -> A15；F5.11 -> A14, A15。

ID	原子 claim	直接实验与主要结果	可靠性	安全措辞与缺口
F5.1	DEER 的高置信 trial answer 后再生成 formal readout 可能冗余	固定脚本重算 486 个 Dev readout pairs: trial/readout 72 次不一致 (14.81%); accuracy 88.68%/88.48%; readout 平均 470.5 output tokens	中高 (Dev 配对)	原始 artifact 与 grader 可复算；仍无 test，且该比较不等于部署式 latency 消融
F5.2	confidence > 0.995 时直接交付 valid trial answer 的 fast path 有独立价值	Dev: Qwen -0.33/+2.39 pp, DeepSeek +1.44/+2.01 pp; Train 也为 Qwen +0.65/+3.04 pp、DeepSeek +1.41/+1.90 pp。Dev 335/684 fast commits	中高 (train/dev 配对)	组件级方向在两个 split、两个模型上多数同向；尚无 test，Dev Qwen 有轻微 accuracy trade-off
F5.3	完整 DEER-inspired online controller 在 dev 三 seed 上接近中性宏准确率并显著省 token	36/36 run directories 与 1,368 rows 统一审计通过；environment-macro Δacc -0.75 pp、fair saving 34.2%；seed 范围 [-6.1, +4.2] pp、[25%, 44%]	中高 (Dev bank)	数据完整性已强化；结果仍 seed-sensitive、无 test，且 online full baseline 并非严格同轨迹反事实
F5.4	完整 controller 比 online DEER 同时更准、更省	Environment-macro: accuracy difference +1.96 pp, 95% CI [-5.04, +8.97]；saving difference +12.11 pp, CI [+0.68, +22.85]	中低	“宏平均下 saving 更高、accuracy 不可区分”可说；不能声称 accuracy 显著更高
F5.5	DEER-inspired 相对 DEER 的 saving 优势不依赖聚合方式	Problem-pooled 684 题: Inspired saving 36.26%，DEER 37.74%，即 Inspired 反而低 1.48 pp；accuracy 为 88.74% vs 84.65%	低/被反例削弱	必须明确 macro 是 benchmark/environment 等权；正文的“saves more”不能不加口径限定
F5.6	Verification branch 提升了 Stage-1 candidate 的正确率	固定 raw audit: 117 个首 branch candidates 中，最终正确数净变化 0 (79 对-> 对、36 错-> 错、各 1 次正反翻转)；100 次 branch commits accuracy 69%，matched full 78%	高可靠反证/claim 不支持	不应写“verification protects accuracy”或把收益归功于 branch
F5.7	Verification branch 的 64-token 成本换来了有效验证	117/117 个 first-branch verification 均恰好 64 tokens 且 finish_reason=length；直接 Stage-1 commit 的反事实宏准确率不变，saving +0.764 pp，少 38,990 output tokens	高可靠反证/claim 不支持	现设计更像被截断的继续推理；需要新 verdict 设计或删除这一贡献表述
F5.8	128/256-token falsification verdict 可解决 verification 问题	单个真实 branch 的 MLX 3-bit smoke 在 128 和 256 tokens 均未稳定产出 verdict	低	仅为 feasibility smoke；不能进入主结果
F5.9	Boundary confidence 是有效 signal	DEER frozen contrast、fast-path replay、online 三 seed 结果共同同向	中	可写 promising / provides constructive evidence；尚不能写成完成验证的通用方法
F5.10	Boundary-confidence controller 已跨 split、规模和架构泛化	当前 online full test、新模型/32B confirmation 尚缺	低/未完成	这是优先级最高的新增大算力实验之一
F5.11	当前方法实现了 DEER v3 的校准置信度 C_cal	当前 confidence 是答案 token probability 的模型相关聚合，未实现考虑 token-level variance 的 C_cal	低/不支持	不得在论文中暗示使用 DEER v3 校准；可作为下一版方法实验

8. 跨 finding 的共同依赖

依赖	影响范围	当前状态	对可靠性的影响
最终答案 grader 正确性	几乎所有 accuracy、recovery、direction-of-effect 结果	Task B 两位标注者均完成 89/89；是否判对的一致率 94.38%，kappa=0.706，仍有 5 个 verdict 冲突；样本为 risk-enriched 而非总体随机样本	支撑 grader 在困难样本上的较高一致性；不能把 8%-12% 的分层样本错误率外推为总体错误率
Taxonomy 人工一致性	F1.6-F1.7	Task A 两位标注者均完成 134/134；精确一致 47.76%，kappa=0.286，70 个冲突主要集中在 A/D 定义	完成回收不等于 taxonomy 稳定；仲裁前只能报告分歧结构，不能给最终类别比例
Token accounting 口径	F2、F3、F4、F5 的所有 saving claims	output-token 计费可复算；不同章节存在 net dense-probe、fair/all-generated、macro/pooled 多种视图	图表和正文必须同时写清 numerator、probe/readout 是否收费、聚合权重
Preregistration provenance	F2 的可信度	split、gates、rule hashes 和 artifacts 已留存	建议在最终 release 中提供一份不可变 manifest/commit 对照表
Domain scope	所有 finding	仅 MATH500、AMC23、AIME24，均为可判分竞赛数学	任何对 code、open-ended、agentic reasoning 的外推都只有低可靠
Sampling comparability	F5 online vs full	online 多请求会改变 sampling path，full 并非严格 paired trajectory	F5 的 vs-full accuracy 只能称 approximate；同 controller 间 paired comparison 更可信

9. 当前最值得补的实验

按“能提升核心 claim 可靠性”排序：

- Boundary-confidence 的 held-out test**：固定方法与阈值，在 test 上运行 DeepSeek-7B、Qwen3-8B；它决定 F5 能否从探索性结果升级为论文核心方法贡献。
- Simple vs CertalIndex probe-prompt ablation**：在同一完整 prefixes 上重新生成 CertalIndex probes，比较首次 consensus 时间、false consensus、saving 与 accuracy；它决定“probe prompt 能否通过延迟共识改善 trade-off”。
- 拆开 fast path 与 branch 的在线消融**：至少比较 DEER、DEER+fast、DEER+fast+branch。现有证据已经支持 fast path，却不支持 verification branch；不做消融会使方法归因错误。
- 重设计或移除 verification**：若保留，必须有短、可解析的 falsification verdict，并证明它改变候选正确率；否则论文应把贡献写成 boundary-confidence fast commit，而不是 verification branch。
- Probe-density / probe-cost 消融**：在同一 frozen bank 上系统比较 interval、probe length 和理想 KV-reuse cost，量化 probe tax 可降低到何种程度。
- 完成人工仲裁**：Task A 先统一“最终候选答案 vs 中间量/placeholder”的 A/D 边界；Task B 仲裁 5 个 verdict 冲突并补全缺失字段。
- 跨 domain 复现**：在预算允许时加入 GPQA、code 或其他非竞赛数学任务，检验 false consensus 是否为数学之外的普遍现象。

10. 建议立即修订的论文措辞

当前倾向	更可靠的写法
“Consensus is not a useful stopping signal.”	“Short local consensus is severely miscalibrated; longer persistence reaches a TJE-like trade-off, but pure agreement remains below DEER stop safety in our tested window range.”
“No consensus rule can be safe and saving.”	“No rule in our preregistered 17,712-rule consensus space clears the conservative gate on development, and none clears it jointly on development and held-out test.”
“The safest stop costs 1.85 pp.”	“The development minimum is 1.85 pp; the confirmed result is frontier stability and an empty joint gate, not the exact floor.”
“DEER stays within about 1 pp on the same models.”	“DEER is near-neutral on Qwen3-8B but loses 4.83 pp on DeepSeek-7B, while still outperforming the consensus frontier near the low-drop region.”
“The verification branch escapes the accuracy tax.”	“Boundary confidence, especially the high-confidence fast path, provides exploratory evidence beyond consensus; the current verification branch has not shown independent accuracy benefit.”
“Inspired saves significantly more than online DEER.”	“Under environment-macro weighting, Inspired saves 12.1 pp more (95% CI +0.7 to +22.9); problem-pooled saving is 1.5 pp lower, so the advantage is aggregation-dependent.”
“Adaptive probing does not work.”	“The preregistered adaptive-event family is dominated within our current trigger and rule grid.”

11. 维护规则

新增实验后只做三件事：

- 1. 在对应 claim 行加入实验范围、主结果和 artifact；
- 2. 检查 claim 的量词是否与新实验范围一致，再升降可靠性；
- 3. 若不同聚合、模型或 split 给出相反方向，不覆盖旧结果，而是拆成新的原子 claim。

论文中出现的新数字或结论，在进入 abstract/introduction/conclusion 前，应先在本文档拥有独立 ID、直接 artifact 和明确可靠性。

Appendix：具体实验数据与图表

本附录提供主矩阵中 43 个原子 claim 的落点。百分比均按对应实验自己的聚合口径报告；不同实验之间不得跨口径直接相减。A1-A3 使用同一 Governor v2 multivariate diagnostic 重算；A5-A13 的扩展核查由 统一 evidence audit 固化，并输出 summary JSON 与逐环境 CSV；汇总图由 附录绘图脚本 从这些固定 artifact 生成。

A1. Governor v2 多元数据范围与完整性

统一设置：DeepSeek-R1-Distill-Qwen-7B 与 Qwen3-8B, MATH500/AMC23/AIME24, seeds 42/43/44, 共 18 个 development environments; dense simple@32 每 64 main tokens probe。MATH500/AMC23 main cap 为 16K, AIME24 为 32K。pooled 按题加权；macro 对 18 个环境等权，避免 MATH500 的题量主导结论。

指标	Problem-pooled	Environment-macro
Main trajectories	2,736	18 environments
Probe rows	229,693	-
Empty probe answers	1,406 (0.6%)	0.4%
Natural completion	2,590 (94.7%)	91.3%
Mean main tokens	5,404	9,059
Final accuracy	88.6%	78.9%
Whole-trajectory unanimous coverage	11.5%	4.7%
Whole-trajectory unanimous accuracy	97.5%	98.1%

Model	Benchmark	n (3 seeds)	Full accuracy	Last-5 unanimous false consensus
Q3-8B	AIME24	72	73.6%	23.1%
Q3-8B	AMC23	96	86.5%	4.0%
Q3-8B	MATH500	1,200	91.2%	6.4%
DS-7B	AIME24	72	47.2%	48.5%
DS-7B	AMC23	96	85.4%	4.5%
DS-7B	MATH500	1,200	89.8%	10.1%

数据源：统一重算报告、cross-axis CSV、可复现脚本。本项将 F1.1-F1.2 的主要证据升级为跨模型、跨 benchmark、跨 seed 的 matched-protocol 数据；早期 Stage 1 单次实验仅保留为 provenance audit。

A2. Agreement calibration、false consensus 与 window sensitivity

Calibration 使用轨迹末尾 last-(w) window、至少 3 个非空答案，以最终答案正确性作为 (y)；CCE 同时报告 problem-pooled 与 environment-macro。完全一致答案的正确性使用项目 grader；下表中的 false-consensus rate 是其补集。作为对照，全轨迹 cumulative CCE 为 0.204 pooled / 0.241 macro；cumulative unanimous coverage 为 11.3% / 4.6%，其中 false consensus 为 1.9% / 1.5%。

Window (w)	CCE pooled / macro	Unanimous coverage pooled / macro	Unanimous accuracy pooled / macro	False consensus pooled / macro
3	0.124 / 0.201	83.7% / 88.0%	89.1% / 83.6%	10.9% / 16.4%
5	0.124 / 0.203	78.7% / 84.4%	90.3% / 84.0%	9.7% / 16.0%
8	0.117 / 0.200	73.9% / 80.6%	91.9% / 84.7%	8.1% / 15.3%




图 1: 图 A2a: 18 environments 上 w=3/5/8 的 agreement calibration。点大小表示 pooled 样本量；橙色环境宏平均避免 MATH500 主导。

作为反事实敏感性检查，strict stop 在首次出现连续 (w) 个非空、规范化等价答案时提交，并计入已消费的 probe output: w=3/5/8 的 macro accuracy drop 分别为 -46.60/-29.99/-17.29 pp, macro net saving 为 82.3%/66.1%/51.4%。w=3 产生 1,478 次错误提交；在实际停止的轨迹上平均节省 4,706 main tokens。因此增大 window 明显降低风险，但不能单独解决错误早停。

Strict unanimous stopping is highly window-sensitive




图 2: 图 A2b: strict unanimous stop 的 accuracy-saving window sensitivity。该反事实不是最终 Governor rule。

数据源: calibration CSV、strict-stop CSV。A2 现在直接支撑 tested windows/settings 下的 agreement miscalibration 和 window sensitivity, 不再依赖单 seed 的 w=5, n=36 局部点。

A3. Probe-1、first-consensus recovery 与 consensus time

Probe-1 是 64 main tokens 处的第一次 completion, 只作为 early-readout control。主要 recovery 证据使用首次 trailing window (至少 3 个非空答案) 达到 share (≥ 0.8) 的 dominant answer。

Window (w)	Reached pooled / macro	Recovery	Overthinking	Recovery:overthinking	Probe-1 wrong -> correct final pooled / macro
3	98.9% / 99.6%	1,204	36	33.44:1	86.0% / 78.0%
5	98.8% / 99.5%	1,137	39	29.15:1	86.0% / 78.0%
8	95.8% / 98.1%	867	44	19.70:1	86.0% / 78.0%

主分析 (w=5) 的 1,137 次 recovery 与 39 次 overthinking 在六个 model $\times$ benchmark cells 中方向一致; 各 cell 的原始比值至少为 24.4:1, 两个 AIME24 cell 没有观察到 overthinking。首次共识答案与 final answer 不同的轨迹为 1,411 条, 其中 1,139 条最终正确。由此, consensus-recovery claim 明显强于 Probe-1 控制项。

First-consensus time is descriptive, not causal ($w=5$, $\text{share} \geq 0.8$)




图 3: 图 A3: $w=5$ 首次共识时间与最终正确率。绝对 token 分箱呈下降, 但按完整轨迹相对位置归一化后不单调, 因此只能作为描述性相关。

数据源: mechanism CSV、consensus-time CSV。A3 直接支撑 F1.2-F1.3; “晚共识更差”不再作为稳健 F1.4 证据, 因为归一化位置不支持单调关系。

A4. False-consensus taxonomy 与当前人工审计状态

状态: 尚无可报告的人工标注结果。完整导出包含 134 个去重案例, 已进入 Task A taxonomy 页面, 但 repo 中尚未出现 Task A/Task B 返回的 annotations_P*.csv。双人标注、inter-annotator agreement 和冲突仲裁均未完成。

早期 28 例 AI-assisted 分类只能用于设计 taxonomy 和标注界面, 不能视为人工实验结果, 也不能支撑类别比例或“probe 格式伪影占比”等正文 claim。A4 当前只记录数据准备状态; F1.6-F1.7 均标为未验证, 待双人标注回收后再填入类别计数、比例、agreement 和仲裁结果。

A5. 17,712-rule Development sweep 与 conservative gate

每条规则覆盖 (2) models × (3) benchmarks × (3) seeds × train/dev 两个 split, 即 36 个 environment-split cells; 17,712 条规则共形成 637,632 行。下表先单独定义 selection 使用的三个量, 避免把规则级和 cell 级统计混在一起。

规则级量	明确定义
D_model(r)	对每个 (split, model), 先对其 benchmark × seed cells 的 accuracy drop 取宏平均, 再取所有 train/dev (split, model) 中的最大值; 越小越安全
D_benchmark(r)	对每个 (split, benchmark), 先对其 model × seed cells 的 accuracy drop 取宏平均, 再取所有 train/dev (split, benchmark) 中的最大值; 越小越安全
PSF(r)	36 个 train/dev cells 中 net total-token saving 严格为正的比例; 越大越稳健

Conservative gate 要求 D_model <= 1.5 pp、D_benchmark <= 2.0 pp、PSF >= 0.8。结果是 0/17,712 条规则通过; 即使只看 D_model <= 1.5 pp 也仍为 0 条。
下面的“分位数”是: 先为**每一条规则**计算上述 D_model(r), 再对 17,712 个规则级数值组成的分布取分位数; 它不是 problem、probe、environment cell 或 token saving 的分位数。

规则集合	Min	P1	P5	P25	P50
Development selection: D_model(r)	1.852	3.370	4.259	10.722	20.074

数值单位为 percentage points, 使用 development phase 的 train+dev selection rows。早期版本曾并列完整四模型 Test 分位数, 但其中 Llama run 已确认发生退化乱码生成, 因此该行撤回。有效的同两模型 Dev/Test cross-split 比较独立放在 A8。
作为方向性补充, 在 637,632 个 development rule-cell 中, 67.72% accuracy 下降、6.75% 上升、25.53% 不变。达到最小 D_model = 1.852 pp 的规则在 Dev 仍为负净节省: DeepSeek -8.9%, Qwen -8.3%。这些是另外两种统计口径, 不再塞入 规则分位数表。




图 4: 图 A5: 17,712 个规则在 Development selection (train+dev) 上的 worst-case per-model accuracy-drop 分布。虚线为 conservative 1.5 pp gate。

数据源: direction-of-effect audit、confirmation frontier、sweep shards 与 checksums、selection blocker。本项支撑 F1.8、F2.2-F2.7 和 F3.4。

A6. Rule-family frontier 与 adaptive event probing

四个 family 是统一七维规则 schema 中的四个搜索模板; family 指主要 evidence/schedule 结构, 其他 maturity、persistence、certainty、validity 和 history 维度仍在各自网格内变化。

Family	简短含义	该 family 最小 D_model	同一规则的 Dev S20
Latest persistence	最新有效答案需连续保持相同若干次, 并可要求跨越最短 token span	8.20 pp	≈9.7%
Window share	最近 (w) 个有效 probes 中, dominant answer share 达到阈值	4.87 pp	≈0.3%
Entropy budget fraction	达到最小预算比例后, 答案分布 entropy 低于阈值才允许接受	1.85 pp	-11.0%
Adaptive event probe	不只定期 probe; 在结论词、entropy drop、反思转折或答案候选等事件处 probe, 再用 latest/window/entropy evidence 判停	9.70 pp	≈4.5%

这里 $S20(r)$ 是该规则在 **18 个 Dev environments** 上 total-token saving fraction 的第 20 百分位; total tokens 包括主生成和该规则实际消费的 probe output, 因此 $S20 > 0$ 表示至少约 80% 的 Dev 环境仍有正净节省。表中每行只是该 family 内 D_model 最小的诊断点, 不是四个正式 selected rules。

Pareto sweep 与预注册选择

实际选择器为每条规则计算三个目标：

- 1. 最大化 $\text{Dev S20}(r)$;
- 2. 最小化 train+dev 的 $D_{\text{model}}(r)$;
- 3. 最小化 train+dev 的 $D_{\text{benchmark}}(r)$ 。

若另一规则在三个目标上都不差且至少一个严格更好，则当前规则被支配；完全同指标的规则 只保留复杂度更低者。17,712 个候选最终形成 93 个非支配点。随后分别对 conservative、balanced、token-efficient 三组预注册 gate 过滤 Pareto 前沿；每组在合格点中 优先选择 Dev S20 最大的、尚未被其他 operating point 使用的规则，再以 PSF、规则复杂度和 rule ID 破同分。

关键结果是：conservative gate 下没有合格点，因此预注册 selector 没有成功冻结三个 operating-point 策略。A6 上表是 family frontier diagnostic，不能写成“Pareto sweep 选出的四个策略”。此外，当前实现以 train+dev 共同构造风险约束、以 Dev S20 排序，并不是先只用 train 剪枝、再完全独立用 Dev 选择。

数据源：selection implementation、protocol、selection blocker、candidate rule registry。本项支撑 F2.7-F2.8；它只否定当前 Dev grid 中的 adaptive-event family，不否定未来 online adaptive controller。

A7. Accuracy-tax 的方向强度

这里比较同一题目的完整生成与反事实早停结果：

- **Harm（破坏恢复）**：完整生成答对，但早停提交错误答案；
- **Rescue（避免过度思考）**：完整生成答错，但早停提交正确答案；
- **Harm/rescue ratio**：Harm 数量除以 Rescue 数量。大于 1 表示早停破坏正确恢复 比挽救错误终局更常见。旧缩写 FC/SW、FW/SC 不再使用。

四个 named Governor rules 均在固定 128-token probe schedule 上运行：

Rule	具体停止条件
Naive consensus	不设最小 token；连续 3 个非空 probe 答案一致即停止，不要求 certainty
Conservative	至少生成 1,024 tokens；连续 8 个 schema-valid 答案一致，且全部标记 certain
Balanced-general	AMC/AIME 至少生成 1,536 tokens；连续 5 个 task-aware-valid 答案一致且 certain
Balanced-math	MATH level <4 至少 768 tokens、level ≥4 至少 2,048 tokens；连续 5 个 schema-valid 答案一致且 certain

Named rule	Stopped	Harm：完整对、早停错	Rescue：完整错、早停对	Harm/rescue
Naive consensus	2,649	1,055	30	35.17
Conservative	2,157	467	32	14.59
Balanced-general	325	60	4	15.00
Balanced-math	1,946	476	26	18.31

Naive 的模型拆分也同向：Qwen 为 $575/16 = 35.94$ ，DeepSeek 为 $480/14 = 34.29$ 。它们不是额外规则，因此不再混入主表。

下面两个 diagnostic 必须区分。First local consensus 在最近最多 (w) 个 probes 中 至少有 3 个有效答案、dominant share ≥0.8 时触发，可能在窗口尚未填满时触发；Strict unanimous 则要求恰好连续 (w) 个非空答案全部一致。

First local consensus (share ≥ 0.8 , 至少 3 个有效答案)

Window (w)	Reached	Harm	Rescue	Harm/rescue
3	2,707	1,204	36	33.44
5	2,702	1,137	39	29.15
8	2,621	867	44	19.70

Strict unanimous stop (连续 (w) 个答案全部一致)

Window (w)	Stopped	Harm	Rescue	Harm/rescue
3	2,707	1,204	36	33.44
5	2,620	730	42	17.38
8	2,456	415	44	9.43




图 5: 图 A7: named rules、first local consensus 与真正 strict-unanimous replay 的 harm/rescue ratio。所有已测设置均大于 1，但两种 consensus 定义不能混称。

数据源: named-rule direction audit、local-consensus mechanism CSV、strict-stop CSV。本项直接支撑 F1.3 与 F3.3；该 ratio 是配对结果的方向强度，不是 causal risk ratio。

A8. Dev-Test cross-split confirmation

比较同一两个 development models 上共同存在的 17,712 个规则；Dev 选择与 Test 评估分别使用各自 split。

指标	结果
Dev gate pass	0
Test-alone gate pass	272
Joint Dev and Test pass	0
272 个 Test passers 回看 Dev	drop min 4.98; median 5.09; max 5.65 pp
Dev least-bad rule	Dev 1.85 -> Test 0.11 pp
Test least-bad rule	Test -0.33 -> Dev 4.87 pp
Across-rule correlation	Pearson r = 0.962

为直观看完整策略空间，图 A8 对 Dev 和 Test 分别画出全部 17,712 条规则。横轴是同两模型的 worst per-model accuracy drop，纵轴是 18 个对应 environments 的 total-token saving 第 20 百分位；每个点是一条规则，黑线是“accuracy drop 更低、saving 更高”的二维非支配前沿。二维线只用于展示，不替代完整 gate 中额外的 per-benchmark drop 和 PSF 约束。




图 6: 图 A8: 同两模型的 Dev/Test 策略点阵与二维 Pareto frontier。红虚线为 1.5 pp per-model gate，灰虚线为零净节省。

此前报告的“完整 4-model Test 有 204 个 test-only passers”混入了无效 Llama run，因此不再作为证据。A8 只使用两个采集有效且 Dev/Test 对齐的 development models；Qwen-32B 作为单独 scale diagnostic 放在 A9，不 与同模型 cross-split frontier 混池。

数据源：cross-split audit、per-rule plot data、rebuild script。本项支撑 F2.5、F2.6、F2.9-F2.10，并说明可靠结论是 joint gate 为空与 frontier 同向，而非某个精确 floor。

A9. Confirmation 覆盖与 unseen-model 边界

Model role	Model	计划范围	实际有效性	结论
Seen development	Qwen3-8B	3 benchmarks × seeds 45/46/47	342/342 trajectories; 13 truncated (3.8%)	完整有效
Seen development	DeepSeek-7B	3 benchmarks × seeds 45/46/47	342/342; 9 truncated (2.6%)	完整有效
Held-out scale	DeepSeek-Qwen-32B	3 benchmarks × seed 45	114/114; 1 truncated (0.9%)	预注册范围内完整；只有单 seed，因此只是规模证据
Held-out architecture	DeepSeek-Llama-8B	原计划 3 benchmarks × seed 45	仅 MATH/AMC，共 108 条；缺 AIME；98 length-stop、95 个空 final answer、仅 1/108 正确	运行无效，不能作为架构证据

32B 并非采集不完整：held-out scale 模型从一开始就只计划 seed 45，以控制 32B confirmation 成本；三 benchmark 的全部 114 题和 probes 均齐全。

Llama 的问题也不只是 cap 设置偏小。98 条 finish_reason=length 轨迹达到 16K cap，但其正文从开头便主要是重复的句点、括号、and 等退化乱码，而不是正常数学推理；95/108 无法抽取答案，最终只有 1 题正确。提交记录说明 AIME24 因 32K “non-terminating generation” 被省略。现有 artifact 没有保存足以唯一归因的 server log、checkpoint hash 或 tokenizer smoke，因此无法判断具体是 checkpoint、tokenizer/chat template 还是 serving/解码错误；但可以确定该 run 不应解释成“较弱模型推理更长”。

因此，目录级审计是 **23 个 observed environments 文件齐全**，但预注册计划实际为 24 个 environments、912 条轨迹；最终只有 23/24、906/912，且其中两个 Llama environments 科学上无效。修复顺序应是：先用固定数学题做可读性与答案抽取 smoke，核对模型权重/tokenizer/template，再进行 cap pilot，最后补齐三 benchmark。

数据源：统一 environment audit、Llama trajectories、采集提交 612cc69b 与 seen-model audit。

A10. Related-work baselines 与 Governor Pareto 位置

Dev benchmark-macro；2 models × 3 benchmarks × seeds 42/43/44。Saving 为 all-generated output-token saving，包含方法辅助输出，不含 prompt/prefill。

三项 baseline 都进行了**独立的 method-specific GPU probing**，不是把 Governor simple@32 probe 改名后重放；每种方法均有 2,736 条逐题记录和 18 个完整 method-environments。但“有真实 probe 数据”不等于三者都是端到端 faithful：

Baseline	原始覆盖	忠实复现的 probe 部分	仍存在的 adaptation / 正确标签
CertalIndex mid	2,736 rows; 27,193 probe calls	原作 suffix、64-token interval、20-token cap、patience=3、certainty 与数学等价 stop rule	只把 live chunk timing 换成相同位置的 frozen prefixes； probe-level faithful, frozen-timing reproduction
DEER	2,736 rows; 14,017 trial calls	官方 Wait trigger、最多 10 次、20-token trial、0.95 门槛、avg1/avg2、Qwen </think> gate 与正式 readout	main path 预先冻结； official probe/readout replay, 不是完整 online controller run
TJE	2,736 rows; 38,672 confidence calls	Figure-2 system instruction、10 个 confidence labels、Wait + </think> trigger、Almost certain 门槛	main trajectory 未在 TJE system prompt 与低置信 Wait 续写下重新生成，且 label 用 constrained choice； frozen adaptation, 不能称 fully faithful

因此，A10 数字是可审计的同轨迹、真实 re-probing 比较。CertalIndex 的 probe faithfulness 最强；DEER 的 trial/confidence/readout 逻辑忠实，但部署路径冻结；TJE 的 probe 内容有原文依据，因主轨迹分布和 constrained decoding 两项改动，只能作为较低保真度的 adaptation。三者均不应直接称为“复现了原论文端到端结果”。

Model	Method	Accuracy	Δacc vs Full	Saving	Main saving	Stop rate
Qwen3-8B	Full	85.44%	0.00 pp	0.00%	-	-
Qwen3-8B	CertalIndex	15.33%	-70.11 pp	90.10%	91.00%	99.78%
Qwen3-8B	DEER	86.22%	+0.78 pp	16.29%	21.37%	41.35%

Model	Method	Accuracy	Δ acc vs Full	Saving	Main saving	Stop rate
Qwen3-8B	TJE	85.00%	-0.44 pp	2.03%	5.82%	22.50%
DeepSeek-7B	Full	79.76%	0.00 pp	0.00%	-	-
DeepSeek-7B	CertalIndex	23.87%	-55.89 pp	76.68%	78.60%	98.67%
DeepSeek-7B	DEER	74.93%	-4.83 pp	20.16%	25.68%	56.07%
DeepSeek-7B	TJE	60.67%	-19.09 pp	65.00%	78.45%	93.44%

逐 benchmark 的三-seed macro 显示重要异质性:

Model	Method	Δ acc range across benchmarks	Saving range across benchmarks
Qwen3-8B	CertalIndex	-83.33 to -43.67 pp	89.85% to 89.98%
Qwen3-8B	DEER	0.00 to +2.33 pp	4.83% to 33.36%
Qwen3-8B	TJE	-1.33 to 0.00 pp	-1.84% to 4.30%
DeepSeek-7B	CertalIndex	-75.00 to -42.67 pp	63.33% to 83.50%
DeepSeek-7B	DEER	-10.33 to 0.00 pp	4.47% to 39.77%
DeepSeek-7B	TJE	-27.78 to -8.67 pp	56.42% to 73.89%

同一 matched harness 中，三个 named Governor consensus baselines 的模型宏结果也明显远离低-drop 区：balanced-task-aware 为 Qwen -34.39 pp / 54.31%、DeepSeek -15.13 pp / 40.42%；conservative 为 -29.69/47.83% 与 -9.94/26.22%；naive 为 -56.48/84.36% 与 -36.22/68.98%。




图 7: 图 A10: Dev 上 train-retained Governor candidates、Pareto boundary 与三项 related-work anchors。横轴为 accuracy drop, 纵轴为 all-generated token saving。




图 8: 图 A10b: 两模型上的 related-work anchors 与 matched named Governor rules。点越靠左上越好；跨 benchmark 范围见上表。

数据源: related-work protocol/commands、raw method-specific outputs、related-work aggregate report、benchmark audit CSV、matched Governor macro、Pareto source CSV。本项支撑 F4.1-F4.5 与 F5.9；上述 fidelity label 必须随结果出现，现有 artifact 仍无 related-work Test rows。

A11. Fast-path-only 配对消融与 trial/readout 冗余

Fast path 规则：若已有 DEER trial answer 非空且 confidence > 0.995，直接交付 trial answer 并省去 formal readout；否则完全保持原 DEER。主轨迹和 branch 均不改变。

Split / model	Original DEER acc	Fast acc	Δ acc	Original saving	Fast saving	Δ saving
Train / Qwen3-8B	79.10%	79.75%	+0.65 pp	17.17%	20.21%	+3.04 pp
Train / DeepSeek-7B	67.55%	68.96%	+1.41 pp	23.61%	25.51%	+1.90 pp
Dev / Qwen3-8B	86.22%	85.89%	-0.33 pp	16.29%	18.69%	+2.39 pp
Dev / DeepSeek-7B	74.93%	76.37%	+1.44 pp	20.16%	22.17%	+2.01 pp

Dev 共 684 trajectories: 340 个 confidence candidates, 5 个 invalid 回退, 335 个 fast commits; 16 个 readout-wrong -> trial-correct, 6 个 readout-correct -> trial-wrong; 避免 131,199 output tokens 和 361,079 prompt/prefill tokens。统一 raw audit 又重算 486 个 Dev triggered pairs: 72 次 trial/readout 不一致 (14.81%), trial/readout accuracy 88.68%/88.48%, formal readout 平均 470.5 output tokens。




图 9: 图 A11-A12: 左图为 Train/Dev fast-path-only 配对组件效果; 右图为完整 online controller 的三 seed environment-macro。

数据源: fast-path report、fixed summary.json、统一 evidence summary、related-work DEER raw artifacts。Train/Dev fast-path table 支撑 F5.2; 固定的 486-pair readout audit 支撑 F5.1。

A12. 完整 DEER-inspired online controller: 三 seed Dev

每个 seed 含 456 method-problem rows; 两模型、三 benchmark。统一 raw audit 检查了 36/36 run directories、1,368/1,368 rows; 所有 manifest 完整, 36 个 run 使用同一个 protocol version 与 config hash。下表为 benchmark/environment 等权宏平均。逐 seed 与三-seed summary 分开, 避免把 macro 当成额外 seed。

Seed	Inspired Δ acc vs Full	Inspired fair saving	Qwen Δ acc / saving	DeepSeek Δ acc / saving
42	-0.36 pp	43.7%	+2.78 pp / 45.6%	-3.50 pp / 41.8%
43	+4.17 pp	33.8%	-1.72 pp / 36.1%	+10.06 pp / 31.5%
44	-6.06 pp	25.1%	-5.56 pp / 41.2%	-6.56 pp / 8.9%

Method summary	Δ acc vs Full	Fair saving	Qwen Δ acc / saving	DeepSeek Δ acc / saving
Inspired	-0.75 pp	34.2%	-1.50 pp / 41.0%	0.00 pp / 27.4%
Online DEER	-2.71 pp	22.1%	-1.54 pp / 18.0%	-3.89 pp / 26.1%

Paired 18-environment bootstrap (Inspired - DEER): Δ accuracy +1.96 pp, 95% CI [-5.04, +8.97]; Δ saving +12.11 pp, 95% CI [+0.68, +22.85]。数据源: 统一 evidence summary、逐环境 metrics、multiseed report、seed-42 formal aggregate。本项支撑 F5.3-F5.4 与 F5.9; 数据完整性问题已补齐, 但仍尚无 test。

A13. 聚合敏感性与 verification-branch 消融

A13.1 Environment-macro 与 problem-pooled

聚合	Inspired accuracy / saving	Online DEER accuracy / saving		Inspired - DEER
Environment-macro	Δ acc -0.75 pp / 34.2%	Δ acc -2.71 pp / 22.1%	+1.96 pp accuracy; +12.11 pp saving	
Problem-pooled (684 problems)	88.74% / 36.26%	84.65% / 37.74%	+4.09 pp accuracy; -1.48 pp saving	

A13.2 Verification branch raw audit

诊断	结果
First branch candidates	117
Correct -> correct	79
Wrong -> wrong	36
Wrong -> correct	1
Correct -> wrong	1
Branch commits	100; accuracy 69% vs matched full 78%
Verification termination	117/117 first branches 恰好 64 tokens, finish_reason=length
Counterfactual: 直接 Stage-1 commit	宏准确率不变; saving +0.764 pp; 少 38,990 output tokens

第一张表说明 F5.4 的 saving 优势依赖 environment-macro weighting，直接支撑 F5.5。第二张表现已由 统一 evidence audit 从 3-seed online raw records 固化重算；它以高可靠度反驳 F5.6-F5.7 当前版本，而不是为 verification 提供正面支撑。117 个 first branch records 中只有 1 个包含后续第二次 branch，表中转移统一按 first branch candidate 到最终 delivered answer 定义。

A14. 协议、置信度与 token accounting

项目	固定定义/实现	影响
Frozen-trajectory Governor	先冻结 main trajectory，再对固定 prefixes 离线 probe；规则只选择 stop/readout	支撑 stopping rule 与 main generation 解耦；不是 online deployment
simple@32	单次 probe completion，最多 32 output tokens；不是 32 次采样	所有 dense-probe 税和 evidence density 解读均依赖此事实
Probe interval	当前主 sweep 为每 64 main tokens 一个可用 probe	使 stop position 足够稠密，也造成较高 probe tax
Governor is_certain	simple@32 文本中不含 uncertainty markers	不是 token-probability confidence
DEER confidence - DeepSeek	Trial-answer token probabilities 的算术平均 (avg1)	模型相关 readout
DEER confidence - Qwen3	Trial-answer token probabilities 的几何平均 (avg2)，并要求 </think>	过滤 incomplete thinking；与 DeepSeek 聚合不同
DEER v3 C_cali	当前未实现 token-level variance calibration	不得声称实现 C_cali
Output-token accounting	$T=s+p$ ；gross $(B-s)/B$ ；net $(B-s-p)/B$	p 为 consumed probe/aux output；不含 prompt/prefill、wall time、KV memory
Online fair saving	$(\text{full output} - \text{all controller-generated output})/\text{full output}$	包含 main、probe、verification、readout output

实现/协议来源：dense probing implementation、related-work README、DEER config、Governor v2 protocol、在线 36-run audit。本项支撑 F2.1-F2.2、F3.1-F3.2、F3.5-F3.6、F4.2、F4.5-F4.6 和 F5.11 的实现边界。

A15. Evidence gaps、反证与待完成实验

对应 claim	当前缺口/反证	升级可靠性所需最小证据
F1.6-F1.7	134 例双标已完成，但精确一致仅 47.76%、kappa=0.286；A/D 操作定义冲突	明确“最终候选答案 vs 中间量/placeholder”边界，仲裁 70 个冲突并输出最终 taxonomy
F2.12	有限 17,712-rule schema 不能覆盖所有 consensus controller/domain	只能收窄量词；新增规则空间也不能证明无限全称
F3.5-F3.6	无 interval × probe length × KV reuse 的直接消融	固定 stop rule 的 probe-density/cost factorial ablation
F4.4/F4.6	Baselines 在 trigger、trial、readout 等处同时不同；不是原论文完整端到端复现	matched-signal ablation；在各论文原设置上的独立 sanity check
F4.1-F4.5	Related-work artifacts 只有 Train/Dev，Test rows 为 0	冻结方法与配置后运行 held-out Test；不得用 Dev Pareto 代替
F5.6-F5.7	Branch 净纠错为 0；所有 commit verification 均被 64-token cap 截断	删除该贡献，或预注册新 verdict/controller 并做组件消融
F5.8	单个真实 branch 的 128/256-token smoke 均未稳定输出 verdict	更简洁的可解析 verdict，先做批量 feasibility，再做 accuracy test
F5.10	完整 boundary controller 尚无 held-out test、32B 或新架构 online 结果	Test × 多 seed × 至少一个 scale/architecture holdout
F5.11	当前没有 DEER v3 C_cal_i	实现 variance-aware calibration，并与现聚合做 paired ablation
F2.11	旧 Llama seed-45 confirmation 仍无效；修复后已完成三 benchmark × 三 seed development scale sweep	若要升级为 held-out architecture confirmation，冻结规则后另跑未参与选择的 Llama split
全部 accuracy claims	89 个 risk-enriched 困难/分歧 cases 双标已完成，kappa=0.706；5 个 verdict 冲突，且样本不能代表总体	完成 5 例仲裁；若要估总体 error rate，按抽样层加权或另抽简单随机样本
全部 domain claims	仅竞赛数学	至少一个 code 或 open-ended reasoning benchmark

本项是“证据落点”而非正面结果：凡主矩阵引用 A15，均表示该 claim 当前必须降格、收窄或保留为 future work。

A16. 修复后的 Llama-8B 多 seed scale sweep

本项只追加新证据，不回写前述历史记录。A9 记录的是旧 seed-45 confirmation run 的 退化乱码与缺失 AIME；A16 使用修复后的 Llama 专属 prompt（显式且仅加入一个 BOS）重新采集 development 数据。两者不是同一 run，旧数据仍保持无效，不能与新结果混池。

修复后范围为 DeepSeek-R1-Distill-Llama-8B × MATH500/AMC23/AIME24 × seeds 42/43/44，共 9 个 environments。Main、dense simple@32 和 adaptive simple@32 各有 1,710 个逐题文件；所有题号、manifest、model/seed 配置和 probe 顺序完整，空 final answer 与乱码字符均为 0。

Benchmark	n (3 seeds)	Full accuracy	Capped	Mean main tokens
MATH500	1,500	88.40%	4.00%	3,882
AMC23	120	88.33%	5.83%	5,620
AIME24	90	47.78%	6.67%	13,160
Overall	1,710	86.26%	4.27%	4,492

在同一 17,712-rule registry 上，本地 replay 精确产生 $(17\{,\}712 \times 27 = 478\{,\}224)$ 行，即每条规则各有 9 train、9 dev 和 9 test environment rows。正式三目标 Pareto 定义仍是：最大化 Dev S20，同时最小化 train+dev worst-model 和 worst-benchmark accuracy drop；该前沿包含 75 条规则。

Operating-point gate	合格 Pareto rules	最佳规则/结果
Conservative	0	-
Balanced	0	-
Token-efficient	4	entropy_budget_fraction__1499bbc05821

最佳 token-efficient 规则的 train+dev worst-model drop 为 1.50 pp，worst-benchmark drop 为 4.17 pp；Dev S20 为 1.39%，Dev mean saving 为 9.35%，18 个 train+dev cells 中 88.89% 为正节省。完全不参与选择的 test split 上，同一规则 worst-benchmark drop 为 1.67 pp、mean drop 为 0.56 pp、mean saving 为 14.29%，但 S20=-1.59%；因此均值有利并不代表跨环境稳健节省。全规则 Dev/Test worst-benchmark drop 的 Pearson (r=0.899)。

下图沿用此前 Train/Dev 二维图的展示口径：先在每个 benchmark 内汇总三 seed，再对三个 benchmark 宏平均 accuracy drop 与 total-decode-token saving；Train 使用 2 pp near-Pareto saving buffer，Dev 只对 Train 保留的 3,408 条规则重画前沿。该二维图得到 98 个 Train strict-frontier 点和 49 个 Dev frontier 点，仅用于直观展示，不替代上面的 75 点正式三目标 Pareto。

Llama-8B Governor candidate rules: train filtering and dev transfer




图 10: 图 A16: 修复后 Llama-8B 的全部 17,712 个策略点。灰点为 Train buffer 外规则, 蓝点为 Train 保留规则, 红线为相应二维 Pareto boundary; 橙色菱形为最佳 token-efficient rule。

数据源: 完整 sweep、逐规则 Pareto CSV、机器可读摘要与 hashes、验收报告、绘图数据。该结果恢复了跨架构 development-scale 证据, 但不是预注册 seed-45 held-out confirmation 的替代品。

A17. Human evaluation 双标回收与验收

两项任务的原始导出均已完整回收：Task A 两位标注者各覆盖 134/134 个 false-consensus cases；Task B 各覆盖 89/89 个 grader-audit rows。没有重复样本、未知题号或非法主标签。CSV 文本行数的表面差异来自末行无 newline，而不是缺题。

A17.1 False-consensus taxonomy

类别	定义	Rater 1	Rater 2
A	Numeric collapse	27	72
B	Expression collapse	3	6
C	Sign error	1	1
D	Reasoning gap	80	28
E	Format hallucination	23	27

精确标签一致为 $64/134 = 47.76\%$ ，Cohen’s kappa = 0.286；70 题需要仲裁。主要分歧是 D -> A：Rater 1 标为 D、Rater 2 标为 A 的案例有 54 个。Rater 1 134/134 均标记 confident，Rater 2 为 129/134。该结果说明 A/D 的操作定义尚未形成 可靠边界；在完成仲裁前，不能把任何一位标注者的类别比例当作最终 taxonomy 分布。

A17.2 Grader 判分核查

指标	Rater 1	Rater 2
完整覆盖	89/89	89/89
标记 grader 错误	8/89 = 8.99%	11/89 = 12.36%
Wilson 95% CI（分层样本内）	[4.63%, 16.75%]	[7.04%, 20.79%]

两位标注者对“grader 是否判对”的一致率为 94.38%，Cohen’s kappa = 0.706。在仲裁前，77 行两人均认为 grader 正确，7 行均认为 grader 错误，5 行的真实 verdict 冲突；Rater 1 另有第 41、57 行选择了 grader 错误但漏填必填的 true verdict。若只看 84 个无冲突 rows，双方共识样本错误率为 $7/84 = 8.33\%$ （Wilson 95% CI [4.10%, 16.22%]）。

Task B 是故意过采样“字符串不同但 grader 判对”和“答案接近但 grader 判错”的 risk-enriched sample；上述 8.99%/12.36%/8.33% 均不能外推成全体 grader decisions 的无偏 population error rate。5 个冲突完成仲裁后，可以报告该分层审计集上的最终错误数，但若要估计总体 error rate，仍需按抽样层与母体规模加权，或另抽简单随机样本。




图 11: 图 A17: 左图显示 Task A 两位标注者的类别分布及低一致性; 右图显示 Task B 分层样本内的 grader-error flags 与 Wilson 95% CI。

数据源: Task A rater 1、Task A rater 2、Task B rater 1、Task B rater 2、验收 summary、Task A 分歧表、Task B 分歧表。因此, human annotation 回收完成, 但 taxonomy 与 grader audit 的最终仲裁尚未完成。

A18. Consensus window 轨迹、related-work anchors 与边际代价

本项补充 A2 的 $w = 3/5/8$ window sensitivity, 并把 strict consensus 扩展到 $w = 2, \dots, 30$ 。分析复用 A1 的 2,736 条 development trajectories: 2 models $\times$ 3 benchmarks $\times$ seeds 42/43/44, dense simple@32 每 64 main tokens probe。某条轨迹在首次出现连续 w 个非空、规范化等价的 **probe answers** 时停止；若始终没有满足条件，则回退到完整生成的 final answer。


所有 saving 均为 all-generated output-token saving: 计入停止前的 main output 和已经消费的 probe completions, 不计 prompt/prefill。Stop accuracy 只在实际早停的题上计算；Overall accuracy 同时包含没有早停、回退到 full generation 的题。因此，增大 w 时 overall accuracy 上升，既可能来自 stop 变准，也可能只是 stop coverage 降低，不能把二者混为“早停更可靠”。

A18.1 Problem-pooled 轨迹

Problem-pooled 让每道题等权，因此 MATH500 占较大权重。短窗口虽然极省 token，却会在大量尚未完成推理的题上提交错误答案；窗口增大后 stop accuracy 单调改善到约 85%，但 coverage 与 saving 同时下降。

Method / w	Token saving	Stop accuracy	Stop coverage	Overall accuracy
Strict $w = 3$	84.6%	45.4%	98.9%	45.9%
Strict $w = 5$	70.3%	62.4%	95.8%	63.5%
Strict $w = 8$	56.5%	73.5%	89.8%	75.1%
Strict $w = 12$	44.9%	79.2%	83.5%	80.7%
Strict $w = 16$	36.0%	82.9%	76.0%	84.3%
Strict $w = 20$	29.6%	84.1%	68.1%	85.9%
Strict $w = 25$	23.0%	84.9%	57.5%	86.8%
Strict $w = 30$	18.4%	85.3%	49.1%	87.5%
TJE (frozen)	27.1%	78.8%	63.9%	82.4%
DEER (frozen)	28.8%	89.6%	72.8%	84.2%

在 pooled 口径下， $w = 12$ 同时比 TJE anchor 有更高 saving 和略高 stop accuracy； $w = 20$ 与 DEER 的 saving 接近，但 stop accuracy 仍低 5.5 pp。在测试的 $w \leq 30$ 范围内，没有 strict-consensus 点同时达到 DEER 的 saving 和 stop accuracy。



Token saving includes main output through stop and consumed probe outputs; prompt/prefill cost is excluded.




图 12: 图 A18a: Problem-pooled 视图。左图把 token saving 与 stop accuracy 画在同一 window 轴上; 右图直接显示 accuracy-saving operating trajectory 及 DEER/TJE anchors。

A18.2 Environment-macro 轨迹


Environment-macro 对 18 个 model $\times$ benchmark $\times$ seed cells 等权，避免 MATH500 主导结论。难度更高的 AMC23/AIME24 权重增加后，strict consensus 的绝对 stop accuracy 明显低于 pooled 结果，但“窗口增大提高可靠性、牺牲 coverage/saving”的方向保持不变。

Method / w	Token saving	Stop accuracy	Stop coverage	Overall accuracy
Strict $w = 3$	82.3%	32.2%	99.6%	32.3%
Strict $w = 5$	66.1%	48.8%	97.9%	48.9%
Strict $w = 8$	51.4%	62.0%	94.8%	61.6%
Strict $w = 12$	42.3%	66.6%	88.9%	66.6%
Strict $w = 16$	34.1%	71.7%	82.3%	71.6%
Strict $w = 20$	28.1%	74.0%	76.0%	73.6%
Strict $w = 25$	22.4%	74.8%	65.6%	74.8%
Strict $w = 30$	18.5%	74.5%	56.7%	75.9%
TJE (frozen)	32.4%	73.0%	60.8%	71.0%
DEER (frozen)	19.8%	86.6%	53.1%	75.1%

Macro 视图下，TJE 落在长-window consensus 轨迹附近：大约在 $w = 18$ 至 $w = 20$ 之间交换 accuracy 与 saving，二者没有明显的双指标支配。DEER 则仍位于更高 stop-accuracy 区域；即使 $w = 30$ ，strict consensus 的 stop accuracy 仍比 DEER 低 12.2 pp。这个对比支持的不是“所有 consensus 都无用”，而是更精确的结论：


短 local consensus 严重失准；提高 persistence 可把它推到 TJE-like trade-off，但在当前模型、数学 benchmark 和 $w \leq 30$ 范围内，单靠 answer agreement 仍未达到 DEER 的 stop safety。

Environment-macro comparison (18 environments)



Token saving includes main output through stop and consumed probe outputs; prompt/prefill cost is excluded.

图 13: 图 A18b: Environment-macro 视图。与 pooled 图使用同一 metric 定义, 但对 18 个 environments 等权。



A18.3 边际性价比与推荐搜索区间


为避免只凭某一个 operating point 选 window，定义局部有限差分

$$C(w) = \frac{S(w-2) - S(w+2)}{A_{\text{stop}}(w+2) - A_{\text{stop}}(w-2)}.$$

其中 S 为 token-saving ratio, A_{stop} 为 stop accuracy. $C(w)$ 的单位是“每提升 1 pp stop accuracy 所损失的 saving pp”；越低表示 用较少 saving 换来较多 stop-accuracy 提升。若分母不为正，则该相邻变化没有 带来可靠性提升，图中以红色叉号标记。该导数只描述**局部交换率**，不能脱离 绝对 stop accuracy、coverage 和目标安全门槛单独选策略。

Window	Pooled $C(w)$	Macro $C(w)$	解释
4	0.76	0.88	边际交换率最高，但绝对 stop accuracy 过低
8	1.50	1.28	仍有高回报，开始进入可比较区间
12	2.27	1.62	Pooled 已达到 TJE-like stop accuracy
16	3.80	2.93	边际回报明显下降
20	4.84	3.18	Macro 接近 TJE trade-off
24	9.07	21.35	进入强烈 diminishing-return 区
28	13.12	12.42	极小且不稳定的 accuracy 增益

Marginal cost of increasing strict-consensus persistence



Raw adjacent differences are shown in gray; the colored trend spans $w-2$ to $w+2$ to reduce single-window noise.

图 14: 图 A18c: $-d(\text{saving})/d(\text{stop accuracy})$ 的相邻差分与 $w \pm 2$ 局部趋势。纵轴为对数尺度; 越低越好。

图中 $w > 16$ 后边际代价总体上升, 且 $w = 21/25/29$ 等相邻变化出现 stop accuracy 不升反降, 说明逐 window 点已开始受环境异质性与离散 grading 噪声影响。若扩展原 Pareto sweep, 优先加入 $\{8, 12, 16, 20\}$ 作为 strict_unanimous_long 的主 grid; $w = 25/30$ 更适合做 saturation ablation, 而不是默认搜索中心。

最后, harm/rescue 与 stop accuracy 衡量不同现象。Pooled harm/rescue 从 $w = 3$ 的 $1204/36 = 33.44$ 降至 $w = 12$ 的 $262/44 = 5.95$, 再降至 $w = 30$ 的 $69/34 = 2.03$; DEER/TJE 分别为 4.44/5.15。长窗口可以有较低 harm/rescue, 却仍有较低 stop accuracy, 因为 false-stop 还包含“full generation 本来也错误”的 persistent-wrong cases。因此论文不应以 harm/rescue 代替 reference-answer stop accuracy。

数据源: window/anchor 完整 CSV、边际差分 CSV、可复现绘图与聚合脚本、related-work false-stop audit。Strict-consensus replay 对当前 development bank 的证据可靠性为高; 与 DEER/TJE 的相对位置为中, 因为两项 related-work points 是同轨迹 frozen adaptations, 而非原论文完整 online deployment。结论范围仍限于两个 7B/8B 模型、三个竞赛数学 benchmark、三 seeds 与 simple@32 probes。